

# 基于空-谱流形学习的高光谱影像 特征提取研究



## 重庆大学硕士学位论文 (学术学位)

学生姓名：王丽华

指导教师：黄 鸿 教 授

学科门类：工 学

学科名称：仪器科学与技术

研究方向：图像处理

答辩委员会主席：刘玉菲

授位时间：2020 年 6 月

# **Feature Extraction of Hyperspectral Image Based on Spatial-Spectral Manifold Learning**



A Thesis Submitted to Chongqing University  
In Partial Fulfillment of the Requirement for the  
Master's Degree of Engineering

By

**Wang Lihua**  
**Supervised by Prof.Huang Hong**

**June, 2020**

## 摘 要

高光谱遥感影像“图谱合一”，为精准实现地物识别与分类提供了可能。但是，较高的光谱分辨率致使其波段数多、数据复杂，从而造成“维数灾难”。故而，如何在降低数据冗余的同时尽可能地保留原始数据中的有效信息，是目前高光谱遥感影像地物分类研究中的关键。

特征提取是解决“维数灾难”的有效途径，通过特征提取，可降低数据冗余，获得更有解释性的特征，改善分类效果。针对大多传统算法均假设高光谱数据分布于单流形结构而未考虑复杂的多流形特性以及仅依赖光谱信息而忽略空间信息的不足，本文以高光谱影像数据的内在结构为视点，结合流形学习中的图嵌入等理论，开展高光谱遥感影像特征提取算法的研究。论文主要工作如下：

① 梳理了高光谱成像技术和特征提取的国内外研究现状，并对现有的特征提取算法进行剖析，发现大多算法未能充分发掘高光谱数据的多流形属性，且忽略了影像的空间一致性，导致地物分类性能受限，为提出新算法提供理论铺垫。

② 提出了一种监督多流形鉴别嵌入(SMMDE)特征提取算法。该算法依据高光谱数据具有内在的多流形结构分布，首先，对数据进行子流形划分，得到不同类别子集对应的子流形结构；其次，对子流形内的数据构建流形内图和流形间图，以表征各流形的结构特点，并且定义了多流形距离；最后，通过最大化流形间距离分散不同流形上的数据和最小化流形内距离聚集同流形上的数据，以提取各流形上的低维特征。在 PaviaU 和 KSC 高光谱数据集上的实验证明：SMMDE 算法可有效表征高光谱数据的多流形结构，提高地物分类精度。

③ 提出了一种监督空间正则化流形鉴别分析(SSRMDA)特征提取算法。针对传统特征提取算法大多仅研究光谱特征而未考虑空间域内的几何空间信息，本文以流形学习中的图嵌入理论为基础，充分融合了光谱-空间信息，研究了一种新的空-谱算法。该算法通过熵率超像素提取空间特征，再根据图嵌入模型构造光谱域和空间域上的近邻图，并利用标签信息，强化类内数据聚集，提取出更有鉴别力的特征。在 Indian Pines 和 Washington DC Mall 高光谱数据集上的实验表明：SSRMDA 算法比相关方法提取了更有解释力的特征。

综上所述，面对高光谱影像地物分类中遇到的“维数灾难”，本文以流形学习为基础，提出了两种新的特征提取算法，并在高光谱遥感数据集上进行了算法的有效性论证。

**关键词：**高光谱影像；特征提取；流形学习；空-谱联合信息；图嵌入

## Abstract

The hyperspectral remote sensing images realize the “integration of maps and spectra”, which provides the possibility for accurately realizing the recognition and classification of the ground objects. However, the higher spectral resolution result in a large amount of bands and complex data, which leads to "curse of dimensionality ". Therefore, how to keep the effective information in the original data as much as possible while reducing the data redundancy is the key to the classification of hyperspectral remote sensing images.

Feature extraction is an effective way to solve the "dimensionality disaster". Through feature extraction, data redundancy can be reduced, more explanatory features can be obtained, and the classification effect can be improved. In view of the facts that most traditional methods assume that hyperspectral data is distributed in a single manifold structure and the complex multi-manifold characteristic is not considered, and only relying on spectral information while ignoring spatial information. In the paper, taking the internal structure of hyperspectral images data as a viewpoint, and combining the graph embedding theory in manifold learning, carrying out the research on feature extraction methods for hyperspectral remote sensing images. The main work is as follows:

① Introducing research status of hyperspectral imaging technology and feature extraction, analyzing the existing feature extraction methods, and finding that most methods fail to fully discover the multi-manifold property of hyperspectral data, and also ignore the spatial consistency, as a result, the classification performance of ground objects is limited, which provides the theoretical foundation for the new methods.

② A supervised multi-manifold discriminant embedding (SMMDE) feature extraction method is proposed. According to the inherent multi-manifold structure distribution of hyperspectral data. First, the data is divided into sub-manifolds to obtain corresponding sub-manifold structures of different categories of data; secondly, the intra-manifold and inter-manifold graphs are constructed to represent the manifold structure. And defining the multi-manifold distance; finally, by maximizing intra-manifold distance to disperse the data on and minimizing inter-manifold distance to gather the data, to extract low-dimensional features on each manifold. The experiments on the PaviaU and KSC hyperspectral data sets prove that the SMMDE can effectively characterize the multi-manifold structure of hyperspectral data and improve the accuracy of classification.

③ A supervised spatial regularized manifold discriminant analysis (SSRMDA) feature

extraction method is proposed. In the light of the shortcomings of traditional feature extraction methods that only use spectral information without considering spatial features, based on graph embedding theory in manifold learning, the paper fully integrates spatial-spectral combined information and studies a new spatial-spectral method. The method extracts spatial features through entropy rate superpixels, and then constructs the neighboring graphs in the spectral domain and spatial domain according to the graph embedding model, and using the label information to enhance the data aggregation in the class for extracting more discriminative features. Experiments on Indian Pines and Washington DC Mall hyperspectral data sets show that the SSRMDA has a better classification effect than related methods.

To sum up, for the problem of "curse of dimensionality" in the hyperspectral classification, two new feature extraction methods are proposed based on manifold learning. The validity of the methods are verified on the hyperspectral data sets.

**Key words:** Hyperspectral Image; Feature Extraction; Manifold Learning; Spatial-spectral Combined Information; Graph Embedding

## 目 录

中文摘要 .....	I
英文摘要 .....	II
1 绪 论 .....	1
1.1 研究背景及意义 .....	1
1.2 国内外研究现状 .....	2
1.2.1 高光谱成像技术的发展 .....	3
1.2.2 高光谱影像特征提取算法 .....	4
1.3 主要内容及论文结构 .....	6
1.3.1 主要内容 .....	6
1.3.2 论文结构 .....	7
2 高光谱影像特征提取算法 .....	8
2.1 引言 .....	8
2.2 高光谱影像特征提取算法 .....	8
2.2.1 基于统计理论的特征提取 .....	8
2.2.2 基于流形学习的特征提取 .....	10
2.2.3 基于多流形学习的特征提取 .....	16
2.2.4 基于空-谱联合的特征提取 .....	21
2.3 分类精度评价指标 .....	23
2.3.1 混淆矩阵 .....	24
2.3.2 总体分类精度 .....	24
2.3.3 平均分类精度 .....	24
2.3.4 $Kappa$ 系数 .....	24
2.4 高光谱影像数据集 .....	25
2.4.1 PaviaU 数据集 .....	25
2.4.2 KSC 数据集 .....	25
2.4.3 Indian Pines 数据集 .....	26
2.4.4 Washington DC Mall 数据集 .....	27
2.5 本章小结 .....	27
3 基于监督多流形鉴别嵌入的高光谱影像特征提取 .....	28
3.1 引言 .....	28
3.2 相关原理 .....	28
3.3 监督多流形鉴别嵌入 .....	29
3.4 实验结果与分析 .....	32
3.4.1 实验设置 .....	33
3.4.2 PaviaU 数据集实验 .....	33
3.4.3 KSC 数据集实验 .....	35
3.4.4 实验结论 .....	38
3.5 本章小结 .....	39

<b>4 基于监督空间正则化流形鉴别分析的高光谱影像特征提取</b>	40
4.1 引言	40
4.2 相关原理	40
4.3 监督空间正则化流形鉴别分析	41
4.4 实验结果与分析	45
4.4.1 实验设置	45
4.4.2 Indian Pines 数据集实验	47
4.4.3 Washington DC Mall 数据集实验	50
4.4.4 实验结论	51
4.5 本章小结	52
<b>5 总结与展望</b>	53
5.1 工作总结	53
5.2 研究展望	54
<b>参考文献</b>	55
<b>附    录</b>	59
A 作者攻读硕士学位期间发表的论文	59
B 作者在攻读硕士学位期间参与的科研项目及获奖情况	59
C 学位论文数据集	60
<b>致    谢</b>	61

# 1 绪 论

## 1.1 研究背景及意义

兴起于 20 世纪 60 年代的遥感技术是建立在光谱学、地理学、计算机学以及电子学等多学科理论上的一种交叉学科技术，可通过远程感知目标反射或自身辐射的电磁波，对目标物体进行探测和识别<sup>[1,2]</sup>。在学科理论的深入发展下，遥感技术得到提升，随之衍伸出了微波遥感、雷达卫星遥感、高光谱遥感等先进的遥感技术。同时，遥感发展趋势从以数据销售为主过渡到以实际应用为主，并广泛应用于自然资源<sup>[3]</sup>、灾害监测<sup>[4]</sup>、地质勘探<sup>[5]</sup>、农业研究<sup>[6]</sup>等方面。

发展于 20 世纪 80 年代的高光谱遥感<sup>[7]</sup>是当前颇具特色的遥感技术前沿，它的出现和发展使人们对遥感技术的认知产生了新的飞跃，续写了遥感影像历经全色遥感→彩色遥感→多光谱遥感→高光谱遥感的影像信息链。高光谱遥感结合了光谱技术与成像技术，既可以对目标成像又能检测目标的波谱特性，对每个像元形成的几十乃至上百个波段进行连续的光谱覆盖，影像光谱覆盖范围从可见光到短波红外，且波段较多，波段间连续分布，光谱分辨率高达纳米级。图 1.1 为高光谱遥感影像成像原理图，影像是一个三维立体图，包括两个空间维和一个光谱维，每个光谱波段数据可视作一个影像层，多个波段的影像层按顺序叠加构成整个光谱维，意味着高光谱遥感影像蕴含了充足的地物信息<sup>[8]</sup>。




图 1.1 高光谱影像成像原理

Fig.1.1 The imaging principle of hyperspectral image

对比于传统遥感影像，高光谱遥感影像具有以下特点：

### ① 图谱合一

高光谱遥感影像表征光谱信息的同时，有机结合了反映地物几何位置的图像信息，实现了“图谱合一”。相比于普通二维图像，高光谱影像增加了一维光谱特征，形成一个



“图谱合一”的光谱影像立方体，同时表达了图像信息和光谱信息，增强了地物内在特性的表达能力。

## ② 光谱分辨率高

光谱分辨率指卫星传感器接收地物反射波谱时能够辨别的最小波长间隔，表示对影像中地物波谱信息的分辨能力，间隔越小，则分辨率越高。高光谱影像的光谱分辨率非常高，可达到 10nm 以内，光谱范围从可见光延伸到短波红外，甚至中红外，形成一条连续的光谱曲线，较好地保留了地物光谱信息，进而提高影像地物分类识别能力。

## ③ 波段数多

高光谱影像成像时光谱波段范围广，成像光谱仪获取的影像光谱覆盖了可见光到短波红外的光谱区域，波段数高达数百个，数据量巨大。波段间相隔越近，光谱分辨率越高，在相同波谱范围内的影像波段数就越多，相邻波段之间的谱间相关性和波段间相关性也越强，反之，相关性越弱。波段间较强的相关性，造成很大的数据信息冗余，使得直接对高光谱原始数据进行分类识别有一定的挑战。因此，在处理高光谱影像分类时，需要先对数据进行特征提取，降低数据冗余度及波段间相关性。

## ④ 特征表达丰富

高光谱遥感数据包含丰富的空间和光谱特征。影像中的像素与实际地物相关联，像素间的几何位置关系反映了真实地物间的空间关系。另外，每个像素对应一条连续的光谱曲线，不同地物表现出不同的光谱曲线，多而窄的光谱波段使得影像中蕴含大量的光谱信息。根据不同空间特征和光谱特征可实现对地物的精细分类。

综上所述，高光谱遥感影像具有的特点使其能够更全面、精细地获取不同地物的差异性，从而提高地物分类的精细度和准确度。然而，高光谱影像为地物分类带来机遇的同时也面临着一些问题：波段间相关性较强，数据冗余度大；存在“同物异谱”、“异物同谱”现象；数据量庞大，易造成“维数灾难”。针对这些问题，研究有效的数据处理手段，从庞大的数据中提取出有用的特征信息，提升地物分类性能，是当前高光谱影像处理的研究热点。因此，本文开展的高光谱影像处理方法的研究将有利于促进高光谱遥感在实际场景中的应用，具有重要的学术研究价值和应用意义。


## 1.2 国内外研究现状

高光谱成像技术获取的像元包含一系列的窄而连续的光谱波段，光谱分辨率高，波段众多。相比于传统遥感，高光谱遥感能提供更丰富的光谱-空间信息，提高了遥感影像地物分类识别的精准度，拓宽了高光谱遥感的应用范围<sup>[9]</sup>。高光谱遥感应用的扩展主要得益于成像光谱仪和处理数据的特征提取算法的研究发展，成像光谱仪提供所需的遥感影像，为实际应用分析提供数据基础，而特征提取算法揭示了影像数据中的本质特征，加速了对高光谱遥感影像的理解与应用。因此，本文将从高光谱成像技术和特征提取算


法两个角度对国内外研究现状进行阐述。

### 1.2.1 高光谱成像技术的发展

1983 年,世界上第一个成像光谱仪 AIS-1<sup>[10]</sup>成功诞生于美国喷气推进实验室,以推扫方式成像,并在矿物勘探及植被研究等方面取得成功应用,彰显了高光谱遥感的潜力。**1987 年**,该实验室又研制出了第二代成像光谱仪,即**机载空可见光/红外光成像光谱仪(AVIRIS)**<sup>[11]</sup>,共有 224 个波段,光谱范围为  $0.41\mu\text{m}\sim 0.45\mu\text{m}$ 。1992 年,美国海军研发了高光谱数字影像实验仪(HYDICE)<sup>[12]</sup>,采用 CCD 推扫成像,可探测光谱覆盖于  $0.4\mu\text{m}\sim 2.5\mu\text{m}$  范围内的 206 个波段。

星载成像光谱仪在机载成像光谱仪的基础上迅速发展起来。2000 年 7 月,美国发射的 MightStar-II 卫星上成功搭载了傅里叶高光谱成像仪(FTHSI)<sup>[13]</sup>,首次实现干涉成像光谱仪应用于星载平台上,成为第三代成像光谱仪,FTHSI 的光谱覆盖范围为  $400\text{nm}\sim 1050\text{nm}$ ,包含波段数 256 个,光谱分辨率达  $2\text{nm}\sim 10\text{nm}$ ,空间分辨率为  $30\text{m}$ 。同年 11 月,美国宇航局成功发射了世界上第一颗星载民用成像光谱仪(Hyperion)<sup>[14]</sup>,搭载于 EO-1 卫星平台上,使用推扫成像方式,在覆盖于  $350\text{nm}\sim 2600\text{nm}$  的光谱范围内,可探测到 242 个波段,光谱分辨率可达  $10\text{nm}$ ,空间分辨率可达  $30\text{m}$ 。Hyperion 良好的高光谱特性,使其在地质填图、农作物估产及环保等领域具有广阔的应用前景。2009 年 5 月,美国在 TacSat-3 上**搭载高光****成像仪(ARTEMIS)**<sup>[15]</sup>成功发射,成像方式为色散型,光谱范围  $0.4\mu\text{m}\sim 2.5\mu\text{m}$ ,光谱分辨率为  $5\text{nm}$ ,空间分辨率为  $5\text{m}$ 。同年 9 月,美国海军研制了用于海洋监测的高光谱成像仪(HICO)<sup>[16]</sup>,并成功安装在国际空间站上。此外,其他国家也先后研制出各种不同的成像光谱仪,例如:欧空局研制的 CHRIS<sup>[17]</sup>、MERIS<sup>[18]</sup>,德国的 ROSIS,加拿大的 PML、CASI、SASI,澳大利亚的 Hymap 等。

与此同时,我国在高光谱成像技术的研究上也紧跟国际发展前沿。我国成像技术的发展,历经从多波段到成像光谱扫描,从光机扫描衍伸到面阵推扫的研发过程<sup>[19]</sup>。20 世纪 90 年代早期,我国成功研制了新型模块化航空成像光谱仪(MAIS)<sup>[20]</sup>,波段数达 71 个。90 年代后期又陆续研制了推扫式高光谱成像光谱仪(PHI)<sup>[21]</sup>,波段数高达 244 个,光谱范围为可见光到近红外;以及实用型模块化成像光谱仪(OMIS)<sup>[22]</sup>,含波段数 128 个。

我国在发展机载成像技术的同时也非常重视星载成像光谱仪的发展。21 世纪以来,多台星载成像光谱仪成功发射,相关技术达到国际先进水平。2002 年 3 月,在“神州三号”飞船上搭载了我国自行研制的中分辨率成像光谱仪(CMODIS)<sup>[23]</sup>,包含可见光到热红外的 34 个波段,光谱范围为  $400\text{nm}\sim 1250\text{nm}$ 。2007 年 10 月,我国第一台傅里叶干涉成像光谱仪搭载于“嫦娥一号”探月卫星上成功发射<sup>[24]</sup>,包含光谱区间为  $480\text{nm}\sim 960\text{nm}$  范围内的 32 个波段,光谱分辨率为  $15\text{nm}$ ,地物分辨率为  $200\text{nm}$ 。2008 年 9 月,在发射的环境和**减灾卫****星(HJ-1)**搭载了一台覆盖可见光至近红外的航天光谱成像仪<sup>[25]</sup>,光谱范围  $450\text{nm}\sim 950\text{nm}$ ,波段数 115 个,光谱分辨率为  $5\text{nm}$ ,空间分辨率

达 100m。2011 年 9 月,“天宫一号”飞行器搭载了先进的光谱成像仪,其探测波谱范围高达 400nm~2500nm,空间分辨率和光谱分辨率等成像指标是当时国内最高的<sup>[26]</sup>。

另外,“高分专项”工程的实施,使高光谱遥感飞跃进步。高分一号、二号、四号卫星的成功发射,实现了亚米级的高时间和高空间分辨率<sup>[27]</sup>。2018 年 5 月发射的“高分五号”卫星是我国首台高光谱综合观测卫星,用于获取紫光到长波红外光谱区域的高光谱遥感数据<sup>[28]</sup>。“高分五号”是“高分专项”中研制最复杂的卫星,其搭载载荷最多,且光谱分辨率最高,具有高精度、高灵敏度的观测能力,达到了国际先进水平。“高分专项”的建设,将为我国资源利用、农业发展、城市建设、防震减灾、国家安全等领域提供监测服务,推动国家建设与发展。此外,“珠海一号”系列卫星的成功发射,提高了遥感数据的采集能力,对中国卫星大数据的应用带来巨大改变<sup>[29]</sup>。2019 年 9 月发射成功的“珠海一号”03 组卫星包括 4 颗高光谱卫星和一颗 0.9m 分辨率视频卫星,光谱分辨率 2.5nm,空间分辨率 10m,具有 256 个波段,可实现对植被、水体、农作物等进行精准定量分析。

“珠海一号”高光谱卫星遥感相关数据在“非洲沙漠蝗灾”灾情监测及“火神山”医院建设中水域变化分析方面提供了科学支撑,体现了高光谱遥感的优势。

随着成像技术的发展,高光谱成像遥感仪器的光谱分辨率、空间分辨率和时间分辨率都越来越高,获取的高光谱影像数据也越来越繁杂,呈现“大数据”特征。因此,如何有效地实现高光谱遥感影像中的有用数据挖掘、信息提取,是高光谱遥感需要解决的关键问题。

### 1.2.2 高光谱影像特征提取算法

特征提取主要是通过数据处理过程中构造一个投影矩阵,将原始数据从高维空间投影到低维空间中,得到新的低维特征用于最终的识别分类<sup>[30]</sup>。特征提取过程中,在保留有效信息的基础上,尽可能地减小数据冗余,降低数据维度,避免“维数灾难”,降低“同物异谱”、“异物同谱”现象的发生。变换后的低维特征以较少的数据来表征较多的信息,既可提高分类效率又可提高分类精度。

近年来,国内外学者已提出了大量的特征提取算法,为高维数据的处理提供了新思想。主成分分析(Principal Component Analysis, PCA)<sup>[31]</sup>算法最大化保留了原始数据的方差。线性鉴别分析(Linear Discriminant Analysis, LDA)<sup>[32]</sup>算法通过高维数据投影后类内方差最小、类间方差最大,实现同类聚集、异类分散。最大噪声分离变换(Maximum Noise Fraction, MNF)<sup>[33]</sup>算法通过最大化信噪比,降低数据中的噪声干扰。多维尺度分析(Multidimensional Scaling, MDS)<sup>[34]</sup>算法通过保持数据间的欧氏距离不变,实现特征提取。

PCA、LDA、MNF 等都是线性特征提取算法,都是假设高光谱数据分布于线性结构上。显然,此类方法不能体现出数据的非线性结构特性。Bachmann 等<sup>[35]</sup>学者研究发现,高光谱数据具有内蕴的非线性结构,主要是由成像过程中的非线性干扰因素造成的,非线性源主要有电磁波与大气环境的复杂作用、目标和电磁波之间的散射以及光谱分辨率

较高引起的“异物同谱”等因素。研究表明，高维数据中存在的内在非线性低维结构，即为流形结构。

流形学习可以较直观地发现内蕴于非线性高维数据中的低维流形结构，经典的流形学习算法有等距映射(Isometric Feature Mapping, ISOMAP)<sup>[36]</sup>、局部线性嵌入(Local Linear Embedding, LLE)<sup>[37]</sup>、拉普拉斯特征映射(Laplacian Eigenmaps, LE)<sup>[38]</sup>和局部切空间排列(Local Tangent Space Alignment, LTSA)<sup>[39]</sup>等。其中，ISOMAP 算法是在 2000 年由 Tenenbaum 等学者提出的，建立在 MDS 算法基础上，将 MDS 中的欧氏距离替换为测地距离以表征数据的内在几何性质；同年 Roweis 等提出 LLE 算法，保持数据在低维空间中的内在局部几何关系不变；2003 年，Belkin 等提出 LE 算法，通过拉普拉斯表示数据间的局部邻域关系，在低维空间中仍保持原有的数据结构；2004 年，张振跃等提出了 LTSA 算法，通过构造每个数据点的切空间来表示数据的低维流形局部几何空间。然而，这几种都是非线性特征提取算法，在数据处理过程中没有明确的映射关系，不能得到新样本的低维嵌入结果，对新样本无泛化能力。为解决 LLE、LE 及 LTSA 算法处理新样本时的的问题，He 等提出了邻域保持嵌入(Neighborhood Preserving Embedding, NPE)<sup>[40]</sup>算法和局部保持投影(Locality Preserving Projection, LPP)<sup>[41]</sup>算法来分别线性逼近 LLE、LE；Zhang 等<sup>[42]</sup>提出 LTSA 的线性化方法，即线性局部切空间排列(Linear LTSA, LLTSA)。

为更好地理解分析 PCA、LDA、ISOMAP、LPP、NPE 等算法，Yan 等<sup>[43]</sup>提出了一种图嵌入(Graph embedding, GE)框架。图嵌入的核心思想是构造一个能揭示数据结构的图，将高维特征通过投影矩阵映射到低维空间，并保持原始数据间的几何结构关系不变。对于高光谱影像，图嵌入的构图以直观、清晰的方式表达了数据潜在的低维流形结构。在图嵌入框架下，Yan 等提出边界 Fisher 分析(Marginal Fisher Analysis, MFA)<sup>[43]</sup>，定义了类内聚集性和类间分散性准则，将类别信息和流形局部分析结合，通过类内图和类间图的构造使同类数据聚集，异类数据分散，从而使分类效果更好；2017 年，Luo 等<sup>[44]</sup>提出了一种局部几何结构 Fisher 分析算法(Local Geometric Structure Fisher Analysis, LGSFA)，该算法利用数据的近邻点及其重构邻域来体现高光谱影像的潜在特性；同年，Lv 等<sup>[45]</sup>提出了一种协同判别流形嵌入算法(Collaborative Discriminative Manifold Embedding, CDME)，其通过构造基于两个结构化字典的类内流形图和类间流形图，以同时保留类内重构结构和类间几何结构来学习一个低维特征空间，进而增强高光谱地物分类能力。

然而，上述算法都假设高维观测数据的分布属于单一流形结构。但在实际应用中，高维数据中可能存在多个不同的类别子集，且每个子集具有不同的低维子流形，因此单流形学习方法不能发现其嵌入于高维空间中的多流形结构，导致分类性能受限。针对此问题，学者们开始探索多流形学习方法以发现高维数据中的本征多流形结构。Hettiarachchi 等<sup>[46]</sup>提出了一种多流形局部线性嵌入算法(Multiple Manifold Locally Linear Embedding, MM-LLE)，该方法在 LLE 算法的基础上采用监督 K 近邻构造流形近邻图以

保持各流形间的距离, 并通过实验证明了其有效性; Shi 等<sup>[47]</sup>提出了一种监督多流形学习算法(Supervised Multi-Manifold Learning, SMML), 该方法在提取特征时通过最大化类间拉普拉斯矩阵, 有效克服了类内矩阵的奇异问题; Yang 等<sup>[48]</sup>提出的多流形判别分析(Multi-Manifold Discriminant Analysis, MMDA)算法以及 Lu 等<sup>[49]</sup>提出的鉴别多流形分析(Discriminative Multi-Manifold Analysis, DMMA) 算法均用于进行高维数据的特征提取; 王立志等<sup>[50]</sup>提出了一种试图发现高光谱数据中的多流形结构的多流形学习 (Multi-LLGPE, M-LLGPE) 算法, 实验证明了该算法能揭示数据的内在特性, 并提升了高光谱地物分类效果。

此外, 高光谱影像的三维立体图表明影像中不仅含有光谱信息, 还蕴藏着富足的空间信息。单纯地利用光谱信息有可能造成一些分类误差, 有研究表明, 空-谱结合有利于克服因单一光谱不能有效区分地物类别的问题<sup>[51]</sup>。魏峰等<sup>[52]</sup>在 NPE 算法的基础上融入影像中数据的空间信息, 提出了空间一致性邻域保持嵌入(Coherence-Neighborhood Preserving Embedding, SC-NPE)算法; Feng 等<sup>[53]</sup>提出的鉴别空-谱边缘算法(Discriminant Spatial-Spectral Margins, DSSM)通过优化高光谱影像边缘揭示数据空-谱局部结构, 进而提取更多的鉴别特征; 侯榜焕等<sup>[54]</sup>提出的半监督空谱全局与局部判别分析(Semi-Supervised Spatial-spectral Global and Local Discriminant Analysis, S3GLDA)通过半监督与无监督方式将光谱信息和空间信息进行融合, 保留谱域全局判别结构和空域局部判别结构在低维空间的不变性, 进而提取鉴别特征, 提高分类精度。

## 1.3 主要内容及论文结构

### 1.3.1 主要内容

本文以高光谱遥感影像为研究对象, 针对高光谱影像波段众多、波段间相关性强、数据量大、冗余度高等问题, 研究了地物分类中的特征提取方法, 并以流形学习中的图嵌入为理论基础, 提出两种新的面向高光谱地物分类的算法。本文主要研究内容如下:

#### ① 高光谱影像特征提取算法

针对现有的特征提取算法现状, 从基于统计原理、基于流形学习、基于多流形学习、基于空-谱联合四个角度详细介绍了一些常见的特征提取算法, 包括它们的核心思想、实现过程等。为本文后续研究提供理论支撑。

给出几种分类结果的评价指标, 为判断后续实验各算法分类性能做定量分析; 同时介绍几种高光谱遥感影像数据集, 为实验提供数据基础。

#### ② 基于多流形学习的特征提取算法

传统高光谱影像特征提取算法大多都是假设数据位于单流形上, 不能发现嵌入于高维空间中的多流形结构。面对单流形学习方法的不足, 提出一种监督多流形鉴别嵌入(Supervised Multi-manifold Discriminative Embedding, SMMDE)特征提取算法, 该算法在

每个子流形上构建类内流形图和类间流形图以揭示出高光谱数据的多流形结构。通过两个高光谱数据集对该算法与其他相关算法进行实验,结果表明,该算法能提取出更有效的鉴别特征,提高分类精度。

### ③ 空-谱联合特征提取算法

以流形学习中的图嵌入为基础原理,针对传统高光谱影像特征提取算法大都只依赖于光谱信息而未考虑空间结构信息的不足,提出监督空间正则化流形鉴别分析(Supervised Spatial Regularized Manifold Discriminant Analysis, SSRMDA)特征提取算法,该算法通过构造光谱图和空间图来分别表征光谱特征和空间结构特征,使类内数据聚集且类间数据分散,以提取鉴别特征。并在两个数据集上进行了验证,实验表明,与相关对比算法相比,该算法提取出的特征更有鉴别力,分类结果更好。

## 1.3.2 论文结构

本文包含五个章节内容,具体安排如下:

第一章,绪论。首先,介绍高光谱遥感的发展过程,描述高光谱影像的特点及带来的问题,引出特征提取处理高光谱影像的必要性;最后,详细介绍高光谱成像技术及特征提取的国内外研究现状。

第二章,高光谱遥感影像特征提取算法。首先,从统计原理、流形学习、空-谱联合等方面介绍几种常用的特征提取算法,包括各算法的主要思想及实现步骤等;最后,简单介绍高光谱影像分类结果的定量评价指标以及实验中用到的高光谱数据集。

第三章,基于多流形学习的特征提取算法。首先,介绍图嵌入理论;其次,根据相关原理提出监督多流形鉴别嵌入(SMMDE)算法;最后,在 PaviaU 和 KSC 高光谱数据集上实验,将该算法与其他相关算法进行对比。

第四章,基于空-谱流形学习的特征特征提取。首先,介绍处理空间信息的熵率超像素方法,并在此基础上提出了监督空间正则化流形鉴别分析(SSRMDA)算法;最后,在 Indian Pines 和 Washington DC Mall 高光谱数据集上验证该算法的性能。

第五章,总结与展望。概括论文所做研究工作,提出存在的问题并对此作出改进分析。



## 2 高光谱影像特征提取算法

### 2.1 引言

由于高光谱影像光谱分辨率较高,波段众多,波段间相关性强,易造成“维数灾难”问题。特征提取是解决上述问题的有效途径,通过减小数据冗余度,提取有解释性的鉴别信息,降低维度,进而有效提升地物分类性能。

为方便表述,论文中,高光谱数据集为  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \in \mathbf{R}^{D \times N}$ ,  $D$  是原始波段数,  $N$  是样本总数, 类别标签  $l_i \in \{1, 2, \dots, c\}$ ,  $c$  是类别数,  $\mathbf{X}$  通过特征提取后得到  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N] \in \mathbf{R}^{d \times N}$ ,  $d (d \leq D)$  为嵌入维数, 线性变换  $\mathbf{Y} = \mathbf{Z}^T \mathbf{X}$ ,  $\mathbf{Z} \in \mathbf{R}^{D \times d}$  属于投影矩阵。

本章后续内容安排如下: 2.2 节中介绍基于统计原理、流形学习、多流形学习及空-谱联合的高光谱影像特征提取算法; 2.3 节介绍高光谱影像分类中常用的评价指标; 2.4 节介绍论文中实验用到的高光谱数据集; 2.5 节是对本章内容的总结。

### 2.2 高光谱影像特征提取算法

#### 2.2.1 基于统计理论的特征提取

以统计理论为原理构建的全局线性特征提取算法使用前提是原始数据存在线性结构特性,通过某种线性变换方式将高维数据投影到低维空间,并且在低维空间中仍能保持数据间的线性关系,同时保持数据的全局结构不变。常用于高光谱影像的全局线性特征提取算法有: PCA 和 LDA。以下对这两种算法进行详细介绍。

##### ① 主成分分析(PCA)

PCA 的主要思想是将原始高维数据通过正交变换,在低维空间转换为一组线性无关的新特征,原始数据可由新特征线性组合表达,新特征也称为主成分。

定义随机样本  $\mathbf{x} \in \mathbf{R}^{D \times N}$ , 正交向量  $\mathbf{z}_j (j=1, 2, \dots, d)$ , 则有如下表示:

$$\hat{\mathbf{x}} = \sum_{i=1}^d c_i \mathbf{z}_i \quad (2.1)$$

$$\mathbf{z}_i^T \mathbf{z}_j = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \quad (2.2)$$

由式(2.1), 两边同时与  $\mathbf{z}_i^T$  相乘, 则有:

$$c_i = \sum_{i=1}^d c_i \mathbf{z}_i^T \mathbf{z}_i = \mathbf{z}_i^T \hat{\mathbf{x}} \approx \mathbf{z}_i^T \mathbf{x} = \mathbf{x}^T \mathbf{z}_i \quad (2.3)$$

最小化线性表示样本的均方差，可得优化问题如下：

$$\begin{aligned}\min E\left[(\mathbf{x}-\hat{\mathbf{x}})(\mathbf{x}-\hat{\mathbf{x}})^T\right] &= E\left(\mathbf{xx}^T - \sum_{i=1}^d \mathbf{z}_i^T \mathbf{xx}^T \mathbf{z}_i\right) \\ &= E(\mathbf{xx}^T) - \text{tr}\left(\mathbf{Z}^T E(\mathbf{xx}^T) \mathbf{Z}\right)\end{aligned}\quad (2.4)$$

中心化处理样本数据，式(2.4)可转化如下优化问题：

$$\begin{aligned}\max \mathbf{Z}^T E(\mathbf{xx}^T) \mathbf{Z} &= \mathbf{Z}^T \mathbf{C} \mathbf{Z} \\ \text{s.t. } \mathbf{Z}^T \mathbf{Z} &= \mathbf{I}\end{aligned}\quad (2.5)$$

其中， $\mathbf{C} = E(\mathbf{xx}^T)$  为样本的协方差矩阵， $\mathbf{I}$  表示单位矩阵。

根据拉格朗日乘子法，可得：

$$L(\mathbf{Z}) = \mathbf{Z}^T \mathbf{C} \mathbf{Z} + \lambda (\mathbf{Z}^T \mathbf{Z} - \mathbf{I}) \quad (2.6)$$

求解式(2.6)可得：

$$\mathbf{C} \mathbf{Z} = \lambda \mathbf{Z} \quad (2.7)$$

求解式(2.7)，取前  $d$  个最大特征值对应的特征向量，构建最佳映射变换矩阵  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ 。

PCA 算法尽可能地保留了数据的主要信息，通过分析特征值，确定需保留的主成分，去除无关主成分，从而实现特征提取。PCA 不仅可以从原始数据中提取无相关性的新特征，同时还可以去除一些噪声和冗余信息，使数据变得简单、高效，更适合于后续分析。然而 PCA 属于非监督学习算法，容易忽略样本的缺失值，且适用于全局线性化结构的数据，而对于高光谱影像中的非线性数据，并不能较好的揭示其内在结构，从而在提取鉴别特征时受到限制。

## ② 线性鉴别分析(LDA)

1936 年，Fisher 提出了 LDA，是一种监督学习特征提取算法。其中心思想是寻找一个明确的投影方向，使得高维空间中的数据投影到低维空间后，同类数据投影点尽可能聚在一起，非同类数据投影点尽可能地分散。

LDA 算法的目的是寻找最清晰的投影矩阵  $\mathbf{Z}$ ，使样本投影后类内散度矩阵最小化，类间散度矩阵最大化，以使类内聚集，类间远离，进而提取鉴别特征。最佳投影矩阵  $\mathbf{Z}$  由 Fisher 准则获取，则其目标函数可表示如下：

$$\max \frac{\sum_{i=1}^c N_i (\bar{\mathbf{y}}_i - \bar{\mathbf{y}})(\bar{\mathbf{y}}_i - \bar{\mathbf{y}})^T}{\sum_{i=1}^c \sum_{j=1}^{N_i} (\mathbf{y}_j - \bar{\mathbf{y}}_i)(\mathbf{y}_j - \bar{\mathbf{y}}_i)^T} = \text{tr}\left(\frac{\mathbf{Z}^T \mathbf{S}_b \mathbf{Z}}{\mathbf{Z}^T \mathbf{S}_w \mathbf{Z}}\right) \quad (2.8)$$

式中， $c$  为样本类别数， $N_i$  表示第  $i$  类样本的数量， $\bar{\mathbf{y}}_i$  和  $\bar{\mathbf{y}}$  分别表示投影后第  $i$  类样本数据的均值和所有数据的均值， $\mathbf{S}_b$  表示类间散度矩阵， $\mathbf{S}_w$  表示类内散度矩阵，且定



义为:

$$\mathbf{S}_b = \sum_{i=1}^c N_i (\mathbf{m}_i - \mathbf{m})(\mathbf{m}_i - \mathbf{m})^T \quad (2.9)$$

$$\mathbf{S}_w = \sum_{i=1}^c \sum_{j=1}^{N_i} (\mathbf{x}_j^i - \mathbf{m}_i)(\mathbf{x}_j^i - \mathbf{m}_i)^T \quad (2.10)$$

式中,  $\mathbf{m}_i$  和  $\mathbf{m}$  分别表示第  $i$  类样本数据的均值以及所有数据的均值, 且

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{j=1}^{N_i} \mathbf{x}_j^i, \quad \mathbf{m} = \frac{1}{N} \sum_{i=1}^c \sum_{j=1}^{N_i} \mathbf{x}_j^i, \quad \mathbf{x}_j^i \text{ 表示第 } i \text{ 类样本中的第 } j \text{ 个数据。}$$

通过拉格朗日乘子法, 式(2.8)的优化问题可转化为式(2.11)

$$\mathbf{S}_b \mathbf{Z} = \lambda \mathbf{S}_w \mathbf{Z} \quad (2.11)$$

求解上式特征值并按降序排列, 则最佳投影矩阵  $\mathbf{Z}$  可由前  $d$  个最大特征值对应的特征向量构成, 即  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ 。此外, 因为类间散度矩阵  $\mathbf{S}_b$  的最大秩为  $c-1$ , 故投影到低维特征空间后的维数需满足  $d \leq c-1$ 。

LDA 是通过类别标签衡量差异性的监督学习方法, 使原始数据通过投影后, 类内方差最小化而类间方差最大化, 使数据有较好的可分离性, 以提取鉴别特征。相比于 PCA 的模糊性, LDA 的目的更明确, 更好地反映了样本间的差异性。但是 LDA 受样本种类限制, 局限性大, 容易出现过拟合问题。另外, LDA 和 PCA 一样, 也不能揭示出高光谱数据的非线性结构。

### 2.2.2 基于流形学习的特征提取

基于统计原理提出的全局线性特征提取算法, 对于线性结构特性的数据, 可较好地保持数据的全局信息, 但对于非线性数据来说, 容易忽略其真实的几何分布关系。为揭示数据的非线性结构, 学者们提出了“流形(Manifold)”概念。

“流形(Manifold)”是欧氏空间中诸如曲线、曲面等概念的衍伸, 可看做是很多曲面片的叠加, 流形上任意数据点处局部同胚于欧式空间, 可用欧氏距离进行数据间关系度量<sup>[55]</sup>。简单地描述: 一个流形就是一个  $d$  维空间在  $d'$  维空间中( $d' > d$ )被扭曲的结果, 任意一个流形都可以嵌入到更高维度的欧式空间中。图 2.1 是三种典型的流形, (a)是莫比乌斯带, (b)是克莱因瓶, (c)是实射影平面。




图 2.1 流形示例

Fig.2.1 Examples of manifold

流形学习(Manifold learning)是以流形为基础对高维数据进行研究的分析方法,旨在发现高维数据的本质结构和内在规律<sup>[56]</sup>。流形学习假设高维空间中的数据分布位于更低维流形上,在不改变原始高维数据间的几何特征情况下,通过某种方式求出数据从高维空间变换到低维空间的嵌入映射,以实现数据可视化,发现数据的内在特性。

流形学习的数学定义为: 已知高维数据集  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \in \mathbf{R}^D$ , 流形学习的目的就是找到映射关系  $f: \mathbf{X} \rightarrow \mathbf{Y}$ , 使原始数据投影到低维空间, 即  $\mathbf{y}_i = f(\mathbf{x}_i)$ , 得到低维嵌入结果  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N] \in \mathbf{R}^d$ , ( $d \ll D$ ) 属于嵌入维度, 映射关系  $f$  并不改变高维数据的几何结构。

如今, 随着流形学习被广泛应用于数据挖掘、图像处理、深度学习等领域, 许多流形学习方法被学者们提出, 以更好的挖掘高维数据蕴藏的低维流形结构。经典的主要有非线性流形学习算法: ISOMAP、LLE、LE 等, 线性流形学习算法: NPE、LPP 等。本节将对依次对这几种算法进行简介。

#### ① 等距离映射(ISOMAP)

ISOMAP 算法的基本原理是计算数据间的测地距离以便衡量数据的几何关系, 同时保持数据在低维嵌入空间中的内在几何结构不变。ISOMAP 算法是以多维尺度分析(MDS)算法为基础扩展而来的, 区别在于 MDS 算法通过欧氏距离表达数据间的关系, ISOMAP 算法则是利用测地距离对数据进行全局度量, 可以更好地拟合流形中的数据关系。

图 2.2 表示测地距离, 其中, 螺旋型的曲线表示流形,  $P$ 、 $Q$  是位于流形上的两个数据点, 图(a)中的虚线表示两点间的欧氏距离, 未能真实揭示流形上两点间的几何关系; 图(b)中两点间的实际距离, 即测地距离, 可以反映两点间在流形中的实际几何位置关系; 图(c)表示高维数据在低维空间的嵌入表达, 直线表示  $P$ 、 $Q$  间最短路径, 曲线表示两点间测地距离, 两者距离相近(直线近似于曲线), 由于实际计算时, 测地距离不好测量, 故用最短路径近似代替测地距离; 图(d)形象地展示了流形上的高维数据的低维嵌入过程。




图 2.2 测地距离示意图

Fig.2.2 Schematic diagram of geodesic distance

ISOMAP 算法保持了数据间的几何结构从高维空间变换到低维空间时仍不变，保证了数据间相异性，揭示了高维数据中的潜在流形结构。其算法步骤如下：

**Step 1: 构建近邻图  $G$**

通过  $k$  近邻法或  $\varepsilon$  法选取数据的近邻点，将样本点与其近邻点连接，构建反映数据间邻近关系的权值近邻图  $G$ 。对于高维空间中的近邻数据点  $\mathbf{x}_i$ 、 $\mathbf{x}_j$ ，将欧氏距离  $d(\mathbf{x}_i, \mathbf{x}_j)$  设置为两点连接边权值；若  $\mathbf{x}_i$ 、 $\mathbf{x}_j$  无近邻关系，则不连接，其权值无穷大。

**Step 2: 计算测地距离  $\mathbf{D}_G = [d_G(\mathbf{x}_i, \mathbf{x}_j)]_{N \times N}$**

根据近邻图  $G$ ，若点  $\mathbf{x}_i$ 、 $\mathbf{x}_j$  为近邻，则用两点间的欧氏距离表示测地距离；若两点无近邻关系，则利用 Floyd 或 Dijkstra 算法计算两点间最短路径来逼近测地距离。故测地距离计算公式如下：

$$d_G(\mathbf{x}_i, \mathbf{x}_j) = \begin{cases} d(\mathbf{x}_i, \mathbf{x}_j), & \mathbf{x}_i \text{ 与 } \mathbf{x}_j \text{ 为近邻} \\ \min \{d(\mathbf{x}_i, \mathbf{x}_j), d(\mathbf{x}_i, \mathbf{x}_k) + d(\mathbf{x}_k, \mathbf{x}_j)\}_{k=1}^N, & \mathbf{x}_i \text{ 与 } \mathbf{x}_j \text{ 非近邻} \end{cases} \quad (2.12)$$

**Step 3: 计算低维嵌入表达**

由高维数据映射到低维空间时测地距离保持不变，利用测地距离  $D_G$  代替 MDS 算法里的欧氏距离，那么有：

$$\mathbf{B} = -\frac{1}{2} \mathbf{H} \mathbf{D}_G \mathbf{H} \quad (2.13)$$

式中， $\mathbf{H}$  为中心矩阵， $\mathbf{H} = \mathbf{I} - \frac{1}{N} \mathbf{e} \mathbf{e}^T$ ， $\mathbf{I}$  表示单位矩阵， $\mathbf{e} = (1, 1, \dots, 1)^T$ 。

对矩阵  $\mathbf{B}$  进行求解，解得特征值矩阵  $\mathbf{A} = \text{diag}[\lambda_1, \lambda_2, \dots, \lambda_N]$ ，及其对应的特征向量  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_N]$ ，取前  $d$  个最大特征值对应的特征向量，得到低维嵌入表示为  $\mathbf{Y} = [\sqrt{\lambda_1} \mathbf{z}_1, \sqrt{\lambda_2} \mathbf{z}_2, \dots, \sqrt{\lambda_d} \mathbf{z}_d]^T$ 。

ISOMAP 是一种全局算法,能够保持数据的全局结构信息,使高维空间中任意两点间的测地距离关系在低维空间中仍不变,以便较好地表达原始数据间的几何位置关系。但是,ISOMAP 算法仍有不足:选取近邻参数无自适应能力,需要人为设置;需要考虑任意两点间的关系,时间复杂度高,效率低;不能得到明确的投影矩阵,从而无法处理新样本。

## ② 局部线性嵌入(LLE)

LLE 算法的核心思想:对每个样本点利用其近邻点进行线性重构,保证高维数据映射到低维空间时仍保持原有的局部线性结构,进而揭示数据潜在的流形结构,实现特征提取。其具体流程如下:

**Step 1:** 获取样本点  $\mathbf{x}_i$  的近邻

根据  $k$  近邻法或  $\varepsilon$  法获取每个样本点的  $k$  个近邻点。

**Step 2:** 计算局部线性权值矩阵  $\mathbf{W}$

在高维空间中的近邻图中,对样本点  $\mathbf{x}_i$  进行线性重构,利用最小化重构误差得到局部线性权值  $\mathbf{W}$ , 则有:

$$\min \sum_{i=1}^N \left\| \mathbf{x}_i - \sum_{j=1}^N w_{ij} \mathbf{x}_j \right\|^2 \quad (2.14)$$

式中,  $w_{ij}$  表示  $\mathbf{x}_i$  与  $\mathbf{x}_j$  间的权值,且  $\sum_{j=1}^N w_{ij} = 1$ ; 若  $\mathbf{x}_i$  与  $\mathbf{x}_j$  近邻,则  $w_{ij} \neq 0$ , 反之,  $w_{ij} = 0$ 。

利用拉格朗日乘子法求解上式可得出局部权值  $\mathbf{W}$ 。

**Step 3:** 计算低维嵌入结果  $\mathbf{Y}$

高维数据投影到低维空间时,保证其近邻关系一致,利用权值在低维空间里重构样本数据,得到如下目标函数:

$$\begin{aligned} \min \sum_{i=1}^N \left\| \mathbf{y}_i - \sum_{j=1}^N w_{ij} \mathbf{y}_j \right\|^2 \\ = \text{tr} \left( \mathbf{Y}(\mathbf{I} - \mathbf{W})(\mathbf{I} - \mathbf{W})^T \mathbf{Y}^T \right) \\ = \text{tr}(\mathbf{Y} \mathbf{M} \mathbf{Y}^T) \\ s.t. \sum_{i=1}^N \mathbf{y}_i = 0, \frac{1}{N} \mathbf{Y} \mathbf{Y}^T = \mathbf{I} \end{aligned} \quad (2.15)$$

式中,  $\mathbf{M} = (\mathbf{I} - \mathbf{W})(\mathbf{I} - \mathbf{W})^T$ ,  $\mathbf{I}$  为单位矩阵,  $\mathbf{M}$  为对称半正定矩阵。

进一步整理可得到式(2.15)的最优解:

$$\mathbf{M} \mathbf{Y}^T = \lambda \mathbf{Y}^T \quad (2.16)$$

求取式(2.16)的特征值,按照从小到大的顺序取前  $d$  个特征值匹配的特征向量组成

样本  $\mathbf{X}$  的低维嵌入  $\mathbf{Y}$ 。

LLE 无需计算距离矩阵，大大减少了计算量。且 LLE 是局部优化算法，只需考虑流形上近邻点间的关系，在低维空间保持流形的局部几何结构不变，进而提取出低维流形鉴别特征。但 LLE 算法只适合密集的数据集，若数据分布稀疏的话，近邻区域可能不在一个平面上，那么数据间的关联性较弱，就会影响特征提取效果。此外，LLE 只对训练样本有意义，不能得到投影矩阵，故对新样本没有泛化能力。并且，受噪声影响较大。

### ③ 拉普拉斯特征映射(LE)

LE 是基于谱图理论的特征提取算法。其主要思想是：通过拉普拉斯算子实现高维数据的低维嵌入，使高维空间中有相互关系的数据点，投影到低维空间时尽可能靠近。通过局部构建数据间的关系，揭示数据内在的流形结构。LE 算法实现的详细步骤如下：

#### Step 1: 构造局部近邻图 $G$

计算高维空间中的样本点  $\mathbf{x}_i$  与其他所有数据点间的欧氏距离  $d(\mathbf{x}_i, \mathbf{x}_j)$ ，利用  $k$  近邻法或  $\varepsilon$  法将与样本点有邻近关系的点连接起来，构建成一个图。

#### Step 2: 计算权值矩阵 $\mathbf{W}$

根据简单法或热核法确定点与点之间的边权值  $w_{ij}$ ，即：

##### ① 简单法：

$$w_{ij} = \begin{cases} 1, & \mathbf{x}_i \text{ 与 } \mathbf{x}_j \text{ 为近邻} \\ 0, & \mathbf{x}_i \text{ 与 } \mathbf{x}_j \text{ 非近邻} \end{cases} \quad (2.17)$$

##### ② 热核法( $t$ 为热核参数)：

$$w_{ij} = \begin{cases} e^{-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{t}}, & \mathbf{x}_i \text{ 与 } \mathbf{x}_j \text{ 为近邻} \\ 0, & \mathbf{x}_i \text{ 与 } \mathbf{x}_j \text{ 非近邻} \end{cases} \quad (2.18)$$

#### Step 3: 确定低维嵌入表达 $\mathbf{Y}$

为保证高维数据投影到低维空间时数据间局部结构关系保持不变，构造如下目标函数：

$$\begin{aligned}
\min \frac{1}{2} \sum_{i,j=1}^N (\mathbf{y}_i - \mathbf{y}_j)^2 w_{ij} &= \frac{1}{2} \sum_{i,j=1}^N (\mathbf{y}_i - \mathbf{y}_j)(\mathbf{y}_i - \mathbf{y}_j)^T w_{ij} \\
&= \frac{1}{2} \sum_{i,j=1}^N (\mathbf{y}_i^T \mathbf{y}_i + \mathbf{y}_j^T \mathbf{y}_j - \mathbf{y}_i^T \mathbf{y}_j - \mathbf{y}_j^T \mathbf{y}_i) w_{ij} \\
&= \mathbf{Y} \mathbf{D} \mathbf{Y}^T - \mathbf{Y} \mathbf{W} \mathbf{Y}^T \\
&= \text{tr}(\mathbf{Y} \mathbf{L} \mathbf{Y}^T) \\
s.t. \quad \mathbf{Y}^T \mathbf{D} \mathbf{Y} &= \mathbf{I}
\end{aligned} \tag{2.19}$$

式中， $\mathbf{L}$  为拉普拉斯矩阵， $\mathbf{D}$  为对角矩阵，且  $\mathbf{L} = \mathbf{D} - \mathbf{W}$ ， $\mathbf{D}_{ii} = \text{diag} \sum_{j=1}^N w_{ij}$ 。

根据拉格朗日乘子法求解式(2.19)，有：

$$\mathbf{L} \mathbf{Y}^T = \lambda \mathbf{D} \mathbf{Y}^T \tag{2.20}$$

对式(2.20)进行特征值分解，选择前  $d$  个最小的特征值相应的特征向量构成低维嵌入结果  $\mathbf{Y}$ 。

LE 算法通过谱图理论，提取出流形鉴别特征。但 LE 算法也有欠缺的地方：数据映射变换过程中得不到确切的投影矩阵，因而未能处理新样本；热核函数的不同参数  $t$  值产生的效果差距较大，参数优化困难；对数据中的噪声比较敏感，不能有效地学习噪声数据中的内部几何结构。

上述提到的 ISOMAP、LLE 及 LE 算法均是非线性流形学习方法，在数据处理过程中都不能获得清晰的投影矩阵，进而得不到新样本的低维嵌入结果，为待测数据的低维输出表达带来了阻碍，因而限制了这些算法的实际应用。为此，He 等提出了 LLE 和 LE 算法的线性化表达，分别为 NPE 和 LPP，有效解决了样本外学习问题。

#### ① 领域保持嵌入(NPE)

NPE 算法是 LLE 算法的线性逼近，不仅可以学习非线性流形结构，还能保留数据流形的局部线性结构不变，进而提取数据中的有用信息，能够对新样本进行泛化。其实现步骤如下：

Step 1: 构建近邻图  $G$ ，选取样本近邻方法如同 LLE。

Step 2: 计算权值矩阵  $\mathbf{W}$ ，权值  $w_{ij}$  计算方式与 LLE 相同。

Step 3: 计算投影矩阵  $\mathbf{Z}$  及低维嵌入结果  $\mathbf{Y}$

NPE 算法主要通过保留提取的局部线性信息实现特征提取，具体利用局部线性重构来表达流形局部线性结构，并在低维特征空间中保留和高维数据相同的局部线性重构。将低维嵌入结果  $\mathbf{Y} = \mathbf{Z}^T \mathbf{X}$  代入式(2.15)得到目标函数：

$$\min \sum_{i=1}^N \left\| \mathbf{y}_i - \sum_{j=1}^N w_{ij} \mathbf{y}_j \right\|^2 = \text{tr}(\mathbf{YMY}^T) = \text{tr}(\mathbf{Z}^T \mathbf{XMX}^T \mathbf{Z}) \quad (2.21)$$

$$s.t. \quad \mathbf{Z}^T \mathbf{XX}^T \mathbf{Z} = \mathbf{I}$$

按照拉格朗日乘子法，有：

$$\mathbf{XMX}^T \mathbf{Z} = \lambda \mathbf{XX}^T \mathbf{Z} \quad (2.22)$$

通过求解式(2.22)的特征值，取前  $d$  个最小的特征值所匹配的特征向量组成投影矩阵  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ 。

NPE 算法在投影过程中保证了数据的局部流形结构不变，且导出了有效的投影矩阵，解决了新样本的学习问题。但 NPE 存在和 LLE 存在同样的问题：参数优化比较复杂。

## ② 局部保持投影(LPP)

LPP 算法的思想：高维数据映射到低维空间过程中通过构造近邻图来保持原始数据间的局部结构特性。不同的是，LE 直接得到低维嵌入结果，未能处理新样本，LPP 在训练样本从高维空间线性变换到低维空间过程中寻找到一个最优投影矩阵，可直接对新样本进行泛化。LPP 算法步骤如下：

Step 1: 构建近邻图  $G$ ，构图思想如同 LE 算法 Step 1。

Step 2: 计算权值矩阵  $\mathbf{W}$ ，计算方法如同 LE 算法 Step 2。

Step 3: 计算投影矩阵  $\mathbf{Z}$  及低维嵌入结果  $\mathbf{Y}$

LPP 算法在线性变换过程中导出投影矩阵  $\mathbf{Z}$ ，从而可得到原始数据映射到低维空间的表示： $\mathbf{Y} = \mathbf{Z}^T \mathbf{X}$ ，将其代入式(2.19)可得目标函数：

$$\min \frac{1}{2} \sum_{i,j=1}^N (\mathbf{y}_i - \mathbf{y}_j)^2 w_{ij} = \text{tr}(\mathbf{YLY}^T) = \text{tr}(\mathbf{Z}^T \mathbf{X L X}^T \mathbf{Z}) \quad (2.23)$$

$$s.t. \quad \mathbf{Z}^T \mathbf{X D X}^T \mathbf{Z} = \mathbf{I}$$

采用拉格朗日乘子法解决式(2.23)的优化问题，可得：

$$\mathbf{X L X}^T \mathbf{Z} = \lambda \mathbf{X D X}^T \mathbf{Z} \quad (2.24)$$

计算式(2.24)的特征值，取前  $d$  个最小的特征值所对应的特征向量构成投影矩阵  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ 。

LPP 是 LE 的线性逼近，揭示了数据的低维流形结构，并成功得到了新样本的低维嵌入坐标。但 LPP 算法效果受近邻选取影响较大，对噪声的鲁棒性也较差。

## 2.2.3 基于多流形学习的特征提取

ISOMAP、LLE、NPE、LPP 等传统的流形学习算法均假设高维空间中的数据属于单一的流形结构分布，但有学者研究发现高维数据中如果有多个类别属性，那么不同的类别子集通常位于各自的低维子流形上，具有不同的分布结构，因此高维数据通常表现



出复杂的多流形结构特点。如图 2.3 所示，不同类的数据分别位于各自所属流形上。针对此情况，应开展多流形学习来保持各类数据在对应子流形上的局部几何结构。以下介绍两种常见的多流形学习算法。




图 2.3 多流形结构示意图

Fig.2.3 Schematic diagram of multi-manifold structure

#### ① 多流形判别分析(MMDA)

为揭示高维数据的内在多流形特性，2011 年，Yang 等人提出了 MMDA 算法。该算法基于 Fisher 判别准则，引入图嵌入模型，通过构建类内图  $G^w$  和类间图  $G^b$  来表征高维数据的内在结构，其中类内图用于表征各子流形内部的特征信息，类间图用来描述各子流形之间的差异信息，**并在在低维子空间中**，使得来自同类的数据尽可能靠近，来自异类的数据尽量远离，以达到特征提取的目的。MMDA 算法的实现过程描述如下：

在类内图  $G^w$  中，仅考虑来自同类别的数据作为近邻点，可采取  $k$  近邻法和 E 法选取近邻。若  $\mathbf{x}_i$  和  $\mathbf{x}_j$  为近邻关系，则节点  $i$  和  $j$  之间用一条边进行连接；若  $\mathbf{x}_i$  不是  $\mathbf{x}_j$  的近邻点，则节点  $i$  和  $j$  之间无连接边。样本点  $\mathbf{x}_i$  和  $\mathbf{x}_j$  之间的权重  $w_{ij}$  一般根据热核函数进行定义。则权重  $w_{ij}$  一般通过式(2.25)进行定义：

$$w_{ij} = \begin{cases} e^{-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{t}}, & \mathbf{x}_i \text{与} \mathbf{x}_j \text{是近邻, 且} l_i = l_j \\ 0, & \text{其他} \end{cases} \quad (2.25)$$

其中， $t$  为热核参数。

MMDA 算法试图在低维空间中保证相同类别数据的局部结构不变，若样本间的权值矩阵为  $\mathbf{W} = [w_{ij}]_{N \times N}$ ，则：



$$\begin{aligned}
& \min \frac{1}{2} \sum_{i,j=1}^N (\mathbf{y}_i - \mathbf{y}_j)^2 w_{ij} \\
&= \frac{1}{2} \sum_{i,j=1}^N (\mathbf{y}_i w_{ij} \mathbf{y}_i^T + \mathbf{y}_j w_{ij} \mathbf{y}_j^T - \mathbf{y}_i w_{ij} \mathbf{y}_j^T - \mathbf{y}_j w_{ij} \mathbf{y}_i^T) \\
&= \text{tr}(\mathbf{Y}(\mathbf{D}^w - \mathbf{W}) \mathbf{Y}^T) \\
&= \text{tr}(\mathbf{Z}^T \mathbf{X} \mathbf{L}^w \mathbf{X}^T \mathbf{Z})
\end{aligned} \tag{2.26}$$

式中， $N$  表示图  $G^w$  中共包含的节点数， $\mathbf{L}^w = \mathbf{D}^w - \mathbf{W}$  为图  $G^w$  的拉普拉斯矩阵， $\mathbf{D}^w$  为一个对角矩阵，且  $\mathbf{D}^{wii} = \text{diag} \sum_j w_{ij}$ 。

根据式(2.26)，可以计算出第  $k$  类的类别中心：

$$m_k = \frac{\sum_i \mathbf{D}^{kii} \mathbf{x}_{ki}}{\sum_i \mathbf{D}^{kii}} \tag{2.27}$$

那么，高维数据所有类的类别中心可以表示为  $\mathbf{M} = [m_1, m_2, \dots, m_c]$ 。

在类间图  $G^b$  中，根据各类别的类别中心进行构图，则连接类别中心  $m_i$  和  $m_j$  之间的边的权重可表示为：

$$B_{ij} = e^{-\frac{\|m_i - m_j\|^2}{t}} \tag{2.28}$$

由于高维空间中不同类别的数据通常位于各自所在的低维子流形上，为了使各类数据对应的低维嵌入尽可能地远离，可得到目标函数：

$$\max \frac{1}{2} \sum_{i,j=1}^c (\mathbf{y}_i - \mathbf{y}_j)^2 B_{ij} = \text{tr}(\mathbf{Y}(\mathbf{D}^b - \mathbf{B}) \mathbf{Y}^T) = \text{tr}(\mathbf{Z}^T \mathbf{M} \mathbf{L}^b \mathbf{M}^T \mathbf{Z}) \tag{2.29}$$

式中， $c$  为图  $G^b$  包含的节点个数， $\mathbf{L}^b = \mathbf{D}^b - \mathbf{B}$  为图  $G^b$  的拉普拉斯矩阵， $\mathbf{D}^b$  为一个对角矩阵，且  $\mathbf{D}^{bii} = \text{diag} \sum_j B_{ij}$ 。

根据式(2.26)和(2.29)，MMDA 算法的目标函数可进一步转化为：

$$\max \frac{\mathbf{Z}^T \mathbf{M} \mathbf{L}^b \mathbf{M}^T \mathbf{Z}}{\mathbf{Z}^T \mathbf{X} \mathbf{L}^w \mathbf{X}^T \mathbf{Z}} \tag{2.30}$$

根据 Fisher 判别分析框架，MMDA 算法的类内拉普拉斯散度矩阵可定义为：

$$J^w(\mathbf{Z}) = \mathbf{Z}^T \alpha_w \mathbf{Z} \tag{2.31}$$

式中,  $\alpha_w \propto \sum_{i,j=1}^c w_{ij}(\mathbf{x}_i - \mathbf{x}_j)(\mathbf{x}_i - \mathbf{x}_j)^T \propto \mathbf{X}\mathbf{L}^w\mathbf{X}^T$  为类内拉普拉斯矩阵。

同理, MMDA 算法的类间拉普拉斯散度矩阵可定义为:

$$\mathbf{J}^b(\mathbf{Z}) = \mathbf{Z}^T \alpha_b \mathbf{Z} \quad (2.32)$$

式中,  $\alpha_b \propto \sum_{i,j=1}^c B_{ij}(m_i - m_j)(m_i - m_j)^T \propto \mathbf{M}\mathbf{L}^b\mathbf{M}^T$  为类间拉普拉斯矩阵。

根据式(2.31)和(2.32), (2.30)中的优化问题可进一步转化为对式(2.33)的求解:

$$\alpha_b \mathbf{Z} = \lambda \alpha_w \mathbf{Z} \quad (2.33)$$

对式(2.33)的进行特征值分解, 按照降序选取前  $d$  个最大特征值对应的特征向量组成低维嵌入映射  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ 。

## ② 鉴别多流形分析(DMMA)

为使高维空间中来自同一流形的数据更紧密, 来自不同流形的数据更分散, Lu 等人在 2013 年提出了鉴别多流形分析(DMMA)特征提取算法。它将高维数据中的每一个类别子集视作一个子流形, 并通过寻找多个映射向量来揭示高维数据在每个子流形下的内蕴特性。DMMA 算法的基本实现过程描述如下:

首先根据数据之间的相似程度选择各样本点的流形内近邻点  $N^{\text{intra}}$  和流形间近邻点  $N^{\text{inter}}$ , 假设第  $i$  个子流形上的第  $r$  个样本点表示为  $\mathbf{x}_{ir}$ ,  $t$  为每个子流形上的样本点个数,  $\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_c$  分别表示高维数据中  $c$  个不同的子流形的映射向量, 其中  $c$  为高维数据的类别数。DMMA 算法的目的是通过最大化子流形边缘, 提取各子流形的局部鉴别特征, 便于数据的分类。那么 DMMA 的优化问题可以用如下公式表示:

$$\begin{aligned} & \max_{\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_c} J(\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_c) \\ &= J_1(\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_{cc}) - J_2(\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_c) \\ &= \sum_{i=1}^c \left( \sum_{r=1}^t \sum_{p=1}^{k_1} \|\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}'_{irp}\|^2 A_{irp} \right) - \sum_{i=1}^c \left( \sum_{r=1}^t \sum_{q=1}^{k_2} \|\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}_{irq}\|^2 B_{irq} \right) \end{aligned} \quad (2.34)$$

其中,  $\mathbf{x}'_{irp}$  表示  $\mathbf{x}_{ir}$  的第  $p$  个流形间近邻点,  $\mathbf{x}_{irq}$  表示  $\mathbf{x}_{ir}$  的第  $q$  个流形内近邻点,  $k_1$  和  $k_2$  分别代表流形间和流形内的近邻个数,  $A_{irp}$  和  $B_{irq}$  分别为样本  $\mathbf{x}_{ir}$  的流形间权重和流形内权重, 分别描述  $\mathbf{x}_{ir}$  与其流形间近邻和流形内近邻的相似性, 定义为:

$$A_{irp} = \begin{cases} \exp(-\|\mathbf{x}_{ir} - \mathbf{x}'_{irp}\|/\sigma^2), & \mathbf{x}'_{irp} \text{ 为 } \mathbf{x}_{ir} \text{ 的流形间近邻} \\ 0, & \text{其它} \end{cases} \quad (2.35)$$

$$B_{irp} = \begin{cases} \exp(-\|\mathbf{x}_{ir} - \mathbf{x}'_{irp}\|/\sigma^2), & \mathbf{x}'_{irp} \text{ 为 } \mathbf{x}_{ir} \text{ 的流形内近邻} \\ 0, & \text{其它} \end{cases} \quad (2.36)$$

DMMA 算法通过迭代的方式依次求取  $c$  个不同的映射向量, 对于第  $i$  个流形, 其目标函数可以表示为:

$$\begin{aligned} & \max_{\mathbf{Z}_i} J(\mathbf{Z}_i) \\ &= (J_1(\mathbf{Z}_i) + F_1) - (J_2(\mathbf{Z}_i) + F_2) \\ &= \left( \sum_{r=1}^t \sum_{p=1}^{k_1} \|\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}'_{irp}\|^2 A_{irp} + F_1 \right) - \left( \sum_{r=1}^t \sum_{q=1}^{k_2} \|\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}_{irq}\|^2 B_{irq} + F_2 \right) \end{aligned} \quad (2.37)$$

其中,  $F_1 = \sum_{j=1, j \neq i}^c \left( \sum_{r=1}^t \sum_{p=1}^{k_1} \|\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}'_{irp}\|^2 A_{irp} \right)$ ,  $F_2 = \sum_{j=1, j \neq i}^c \left( \sum_{r=1}^t \sum_{q=1}^{k_2} \|\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}_{irq}\|^2 B_{irq} \right)$  为两个常量矩阵, 在求解  $\mathbf{Z}_i$  的过程中可忽略不计。

因此, 式(2.37)可更改为:

$$\begin{aligned} J_1(\mathbf{Z}_i) &= \sum_{r=1}^t \sum_{p=1}^{k_1} \|\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}'_{irp}\|^2 A_{irp} \\ &= \sum_{r=1}^t \sum_{p=1}^{k_1} \text{tr}((\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}'_{irp})(\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}'_{irp})^T A_{irp}) \\ &= \sum_{r=1}^t \sum_{p=1}^{k_1} \text{tr}(\mathbf{Z}_i^T [(\mathbf{x}_{ir} - \mathbf{x}'_{irp})(\mathbf{x}_{ir} - \mathbf{x}'_{irp})^T A_{irp}] \mathbf{Z}_i) \\ &= \text{tr}(\mathbf{Z}_i^T \sum_{r=1}^t \sum_{p=1}^{k_1} [(\mathbf{x}_{ir} - \mathbf{x}'_{irp})(\mathbf{x}_{ir} - \mathbf{x}'_{irp})^T A_{irp}] \mathbf{Z}_i) \\ &= \text{tr}(\mathbf{Z}_i^T \mathbf{H}_1 \mathbf{Z}_i) \end{aligned} \quad (2.38)$$

其中,  $\mathbf{H}_1 = \sum_{r=1}^t \sum_{p=1}^{k_1} (\mathbf{x}_{ir} - \mathbf{x}'_{irp})(\mathbf{x}_{ir} - \mathbf{x}'_{irp})^T A_{irp}$ 。

同理,  $J_2(\mathbf{Z}_i)$  可以简化为:

$$\begin{aligned} J_2(\mathbf{Z}_i) &= \sum_{r=1}^t \sum_{q=1}^{k_2} \|\mathbf{Z}_i^T \mathbf{x}_{ir} - \mathbf{Z}_i^T \mathbf{x}_{irq}\|^2 B_{irq} \\ &= \text{tr}(\mathbf{Z}_i^T \sum_{r=1}^t \sum_{q=1}^{k_2} [(\mathbf{x}_{ir} - \mathbf{x}_{irq})(\mathbf{x}_{ir} - \mathbf{x}_{irq})^T B_{irq}] \mathbf{Z}_i) \\ &= \text{tr}(\mathbf{Z}_i^T \mathbf{H}_2 \mathbf{Z}_i) \end{aligned} \quad (2.39)$$

其中,  $\mathbf{H}_2 = \sum_{r=1}^t \sum_{q=1}^{k_2} (\mathbf{x}_{ir} - \mathbf{x}_{irq})(\mathbf{x}_{ir} - \mathbf{x}_{irq})^T B_{irq}$ 。

根据  $\mathbf{H}_1$  和  $\mathbf{H}_2$ , 上述优化问题可以转化为:

$$(\mathbf{H}_1 - \mathbf{H}_2)\mathbf{Z}_i = \lambda\mathbf{Z}_i \quad (2.40)$$

求解式(2.40)的特征值,按降序选择前  $d$  个特征值相对应的特征向量构成第  $i$  个流形的映射向量  $\mathbf{Z}_i = [\mathbf{z}_{i1}, \mathbf{z}_{i2}, \dots, \mathbf{z}_{id}]$ 。重复上述过程,就得到了高维数据在每个流形下的映射向量  $\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_c$ 。

#### 2.2.4 基于空-谱联合的特征提取

传统的高光谱影像特征提取算法,大多研究只关注于光谱信息,然而,高光谱影像中存在“同物异谱”和“异物同谱”现象,若仅依靠光谱信息进行地物分类难免会出现误分、漏分情况。研究表明,空间特征的融入可以弥补光谱信息的不足,使提取的鉴别特征更完善,有效提高地物分类精度。目前,常用的空-谱特征提取算法主要有空间一致性邻域保持嵌入(SC-NPE)和鉴别空-谱边界(DSSM)。

##### ① 空间一致性邻域保持嵌入(SC-NPE)

NPE 算法在特征提取过程中只利用了高光谱影像的光谱信息,忽略了空间信息,使其分类性能受限。高光谱影像的空间域中含有丰富的空间特征,结合高光谱影像中的空间信息和光谱信息可使提取的特征富含地物信息更细致,以增强算法的分类性能。为此,魏峰等在 NPE 中加入空间信息的表达,提出了 SC-NPE,该算法对每一个像元构建一定大小的环块,通过环块之间的光谱相似性来选取近邻点,计算环块间的距离代替像元间的欧氏距离,以保持数据的局部流形结构。SC-NPE 不仅保持了数据的流形结构不变,而且加入了空间信息,降低影像中噪声的影响,能更好地达到提升地物分类效果的目的。SC-NPE 算法的实现过程归纳如下:

对高光谱影像中的像元  $\mathbf{x}_i$ ,选取以  $\mathbf{x}_i$  为中心的大小为  $r \times r$  ( $r$  为正奇数)的区域作为  $\mathbf{x}_i$  的环块  $S_i$ ,在环块  $S_i$  中,每一个光谱波段都可以表示为一个  $r \times r$  的向量。若  $S_i(B)$  表示环块  $S_i$  在第  $B$  个波段上的值,则环块  $S_i$  和  $S_j$  之间的距离可定义为:

$$D_{SC}(S_i, S_j) = \sqrt{\sum_B d_r^2(S_i(B), S_j(B))} \quad (2.41)$$

其中,  $d_r(S_i(B), S_j(B))$  为两个向量之间的距离。

在高维空间中建立  $\mathbf{x}_i$  的局部邻域  $N(i)$ ,根据环块距离选择相距最近的  $k$  个环块的中心像元作为像元  $\mathbf{x}_i$  的近邻进行线性重构。 $w_{ij}$  表示像素  $\mathbf{x}_i$  与  $\mathbf{x}_j$  之间的连接边权重,如果  $\mathbf{x}_i$  和  $\mathbf{x}_j$  之间无近邻关系,则没有连接,  $w_{ij} = 0$ ; 否则  $w_{ij}$  通过以下误差重构函数来计算:

$$\min \sum_{i=1}^N \|\mathbf{x}_i - \sum_{j \in N(i)} w_{ij} \mathbf{x}_j\|^2 \quad (2.42)$$

其中约束条件为  $\sum_{j=1}^N w_{ij} = 1$ 。

SC-NPE 算法力求保证高维数据的局部邻域结构在低维空间仍保持不变。则目标函数如下：

$$\begin{aligned} \min \sum_{i=1}^N \|\mathbf{y}_i - \sum_{j \in N(i)} w_{ij} \mathbf{y}_j\|^2 &= \text{tr}(\mathbf{Z}^T \mathbf{X} \mathbf{M} \mathbf{X}^T \mathbf{Z}) \\ \text{s.t. } \mathbf{Z}^T \mathbf{X} \mathbf{X}^T \mathbf{Z} &= \mathbf{I} \end{aligned} \quad (2.43)$$

其中,  $\mathbf{M} = (\mathbf{I} - \mathbf{W})(\mathbf{I} - \mathbf{W})^T$ ,  $\mathbf{I} = \text{diag}[1, 1, \dots, 1]$  为单位矩阵,  $\mathbf{W}$  为权重矩阵,

通过拉格朗日乘子法对式(2.43)进行求解, 可得:

$$\mathbf{X} \mathbf{M} \mathbf{X}^T \mathbf{Z} = \lambda \mathbf{X} \mathbf{X}^T \mathbf{Z} \quad (2.44)$$

按照从小到大的顺序对式(2.44)得到的特征值进行排列, 选取前  $d$  个特征值对应的特征向量构成投影矩阵  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ 。

## ② 鉴别空-谱边界(DSSM)

DSSM 是由 Feng 等人在 2015 年提出的面向高光谱影像的空-谱联合特征提取方法, 目的是为了削弱损坏的数据在特征提取及后续分类过程中的影响。其基本原理是通过选择每个像元的局部空间范围, 在该范围内构造像元的空-谱近邻来融入空间信息, 构建了异质空-谱近邻(局部空间区域内的不同类数据)和同质空-谱近邻(局部空间区域内的同类数据), 最后通过优化异质空-谱边界和同质空-谱边界使得来自异类的空-谱近邻像元尽量远离及同类的空-谱近邻像元尽量聚集。DSSM 算法的基本实现过程可以表述如下:

根据高光谱影像的空间结构和光谱信息分别找到各像元的空间近邻点和光谱近邻点。在空间域, 构造以  $\mathbf{x}_i$  为中心的方形空间邻域为  $SN_p(p \times p)$ ; 在光谱域, 根据样本的光谱相似性, 找到像元  $\mathbf{x}_i$  的  $k_o$  个类内近邻点构成同质近邻集  $N_i^o$  和  $k_e$  个类间近邻点构成异质近邻集  $N_i^e$ 。

高光谱数据的异质空-谱边界和同质空-谱边界分别为:

$$J_e = \sum_{k: \mathbf{x}_k \in N_i^e} \left( \frac{a_{ik} \|\mathbf{x}_i - \mathbf{x}_k\|^2}{k_e} \right) \quad (2.45)$$

$$J_o = \sum_{j: \mathbf{x}_j \in N_i^o} \left( \frac{a_{ij} \|\mathbf{x}_i - \mathbf{x}_j\|^2}{k_o} \right) \quad (2.46)$$

其中,  $a_{ik}$  为像元  $\mathbf{x}_i$  和  $\mathbf{x}_k$  的权重, 它可以定义为:

$$a_{ik} = \begin{cases} p \exp(-d_{ik}^2), & \text{若 } \mathbf{x}_k \in SN_p(i) \\ \exp(-d_{ik}^2), & \text{其他} \end{cases} \quad (2.47)$$

式中,  $d_{ik}$  为像元  $\mathbf{x}_i$  和  $\mathbf{x}_k$  的空间欧氏距离。异质空-谱边界主要反映中心像元与其异质近邻点的类间分离性, 该值越大说明类别可分性越好; 而同质空-谱边界主要反映中心像元与其同质近邻点的类内聚集性, 该值越小, 则类内数据越聚集。

像元  $\mathbf{x}_i$  的鉴别空-谱边界可定义为:

$$\delta_i = \sum_{k:\mathbf{x}_k \in N_i^e} \frac{a_{ik} \|\mathbf{x}_i - \mathbf{x}_k\|^2}{k_e} - \sum_{j:\mathbf{x}_j \in N_i^o} \frac{a_{ik} \|\mathbf{x}_i - \mathbf{x}_j\|^2}{k_o} \quad (2.48)$$

式中, 第一项表示像元  $\mathbf{x}_i$  与其异质空-谱近邻的平均距离, 第二项表示像元  $\mathbf{x}_i$  与其同质空-谱近邻的平均距离, 平均邻域边界反映了每个像元周围的局部分散性。

通过最大化空-谱邻域边界, 意在使来自异类的的数据尽可能远离, 来自同类的的数据尽可能聚集在一起, 则对于所有像元, 其鉴别空-谱边界为:

$$\delta = \sum_i \delta_i = \sum_i \left( \sum_{k:\mathbf{x}_k \in N_i^e} \frac{a_{ik} \|\mathbf{x}_i - \mathbf{x}_k\|^2}{k_e} - \sum_{j:\mathbf{x}_j \in N_i^o} \frac{a_{ik} \|\mathbf{x}_i - \mathbf{x}_j\|^2}{k_o} \right) \quad (2.49)$$

令投影矩阵为  $\mathbf{Z}$ , 则式(2.49)的第一项可改写为:

$$\sum_i \sum_{k:\mathbf{x}_k \in N_i^e} \frac{\|\mathbf{y}_i - \mathbf{y}_k\|^2}{k_e} = \text{tr} \left( \sum_i \sum_{k:\mathbf{x}_k \in N_i^e} \frac{\|\mathbf{y}_i - \mathbf{y}_k\|^2}{k_e} \right) = \mathbf{Z}^T \text{tr}(\mathbf{S}_b) \mathbf{Z} \quad (2.50)$$

其中, 离散性矩阵  $\mathbf{S}_b = \sum_{i,k:\mathbf{x}_k \in N_i^e} \frac{a_{ik} \|\mathbf{x}_i - \mathbf{x}_k\|^2}{k_e}$ 。

同理, 式(2.49)的第二项可化简为:

$$\sum_i \sum_{j:\mathbf{x}_j \in N_i^o} \frac{\|\mathbf{y}_i - \mathbf{y}_j\|^2}{k_o} = \mathbf{Z}^T \text{tr}(\mathbf{S}_w) \mathbf{Z} \quad (2.51)$$

其中, 聚集性矩阵  $\mathbf{S}_w = \sum_{i,k:\mathbf{x}_k \in N_i^o} \frac{a_{ik} \|\mathbf{x}_i - \mathbf{x}_k\|^2}{k_o}$ 。

因此, 式(2.49)可转化为如下优化问题:

$$\delta = \text{tr}[\mathbf{Z}^T (\mathbf{S}_b - \mathbf{S}_w) \mathbf{Z}] \quad (2.52)$$

将式(2.52)解得的特征值按照降序依次排列, 则前  $d$  个特征值相对应的特征向量构成投影矩阵  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ 。

### 2.3 分类精度评价指标

为检验各特征提取算法的优良性, 需通过对分类结果进行客观评价。高光谱影像分

类精度评价通常是指实际分类结果与地物真实参考值进行对比,若待测样本的分类结果与其参考值越接近,说明分类精度越高,则对应算法分类性能较好。精度评价通常需要多个评价指标交叉分析验证,本节将介绍几种常用的高光谱影像地物分类评价指标。

### 2.3.1 混淆矩阵

混淆矩阵(Confusion Matrix, CM),也称误差矩阵(Error Matrix),是衡量一个算法模型好坏最基本的指标<sup>[57]</sup>。在高光谱影像精度评价中,通常将实测分类结果与参考值进行对比并将对比结果放在一个混淆矩阵里,由此可计算出分类精度。混淆矩阵定义方法如下:

$$\mathbf{M} = \begin{bmatrix} N_{11} & N_{12} & \cdots & N_{1c} \\ N_{21} & N_{22} & \cdots & N_{2c} \\ \vdots & \vdots & \ddots & \vdots \\ N_{c1} & N_{c2} & \cdots & N_{cc} \end{bmatrix} \quad (2.53)$$

式(2.53)表示对  $c$  类地物分类后的统计结果,  $N_{ij}$  表示第  $i$  类错分数目,  $N_{ii}$  表示第  $i$  类归对

类个数,若  $\sum_{i=1}^c N_{ii}$  数值越大,则表示正确分类的地物越多,算法模型越好,对应地,若

矩阵中非对角线上元素值的和越大,表明误分情况较多,算法性能较差。

### 2.3.2 总体分类精度

总体分类精度(Overall Accuracy, OA)定义为归对类的样本总数占总样本数的比例,它表示所有地物类别总体分类准确度,根据混淆矩阵将其表示为:

$$OA = \frac{\sum_{i=1}^c N_{ii}}{\sum_{i=1}^c \sum_{j=1}^c N_{ij}} \quad (2.54)$$

### 2.3.3 平均分类精度

平均分类精度(Average Accuracy, AA)定义为各类地物分类精度之和的平均值,揭示每类地物的正确分类情况。其公式表示如下:

$$AA = \frac{\sum_{i=1}^c \left( N_{ii} / \sum_{j=1}^c N_{ij} \right)}{c} \quad (2.55)$$

### 2.3.4 Kappa 系数

由于 OA 指标中存在对部分样本(特别是影像边缘残缺样本)错分漏分的情况,不能有效衡量算法分类性能。为了更好地判断高光谱影像的分类效果, *Kappa* 系数(Kappa Coefficient)可靠性更高,它可避免地物类别数和样本数对 OA 的影响,更准确地体现实

际分类结果与真实地物类别的一致性。 $Kappa$  系数表示如下：

$$Kappa = \frac{N \sum_{i=1}^c N_{ii} - \sum_{i=1}^c (N_{i+} \times N_{+i})}{N^2 - \sum_{i=1}^c (N_{i+} \times N_{+i})} \quad (2.56)$$

式中， $N$  表示样本总数， $N_{i+} = \sum_{j=1}^c N_{ij}$  表示每类真实地物被归类到第  $i$  类的样本总和，

$N_{+i} = \sum_{j=1}^c N_{ji}$  表示第  $i$  类真实地物被归类到各类的样本总数。

$Kappa$  系数取值范围为  $0 \leq 1$ ，一般分为三个等级： $Kappa > 0.8$ ，一致性较高、 $0.4 < Kappa < 0.8$ ，一致性一般、 $Kappa < 0.4$ ，一致性较低。相比于 OA， $Kappa$  系数同时考虑了正确分类和误分漏分情况，可以更全面具体地对分类结果作出评价。

## 2.4 高光谱影像数据集

### 2.4.1 PaviaU 数据集

PaviaU 数据集<sup>[58]</sup>是在 2001 年由 ROSIS 传感器采集的 PaviaU 大学区域的遥感影像。其大小为  $610 \times 340$ ，包含从  $0.43 \mu m$  至  $0.86 \mu m$  的 115 个波段，剔除因噪声影响的 12 个波段，选取剩余的 103 个波段进行实验。该数据集包括草地、树木等 9 种地物，其假彩色图和真实地物分布如图 2.4 所示，括号内为相应类别样本数量。

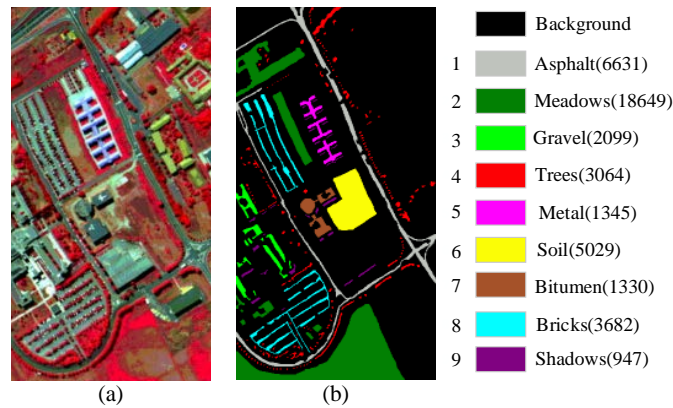


图 2.4 PaviaU 高光谱遥感影像。(a)假彩色图；(b)真实地物图

Fig2.4 The hyperspectral remote sensing image of PaviaU. (a)False-color image; (b) Ground-truth

### 2.4.2 KSC 数据集

KSC 数据集<sup>[58]</sup>是在 1996 年由 AVIRIS 成像光谱仪获取的肯尼迪空间中心 (Kennedy



Space Center, KSC) 影像。其大小为  $614 \times 512$ ，光谱范围  $0.4\text{--}2.45\ \mu\text{m}$ ，共 224 个波段。采用剔除受大气影响及信噪比低的波段后的 176 个波段进行实验。该数据集包含水、泥滩等 13 类地物，其假彩色图和地面真实图如图 2.5 所示，括号内为相应类别样本数量。

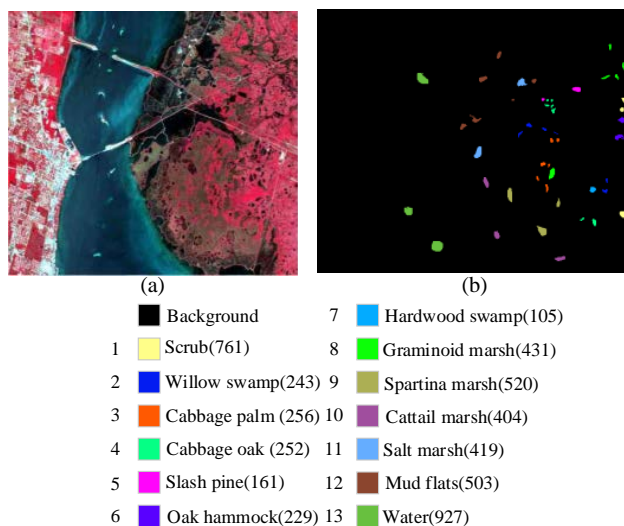


图 2.5 KSC 高光谱遥感影像。(a)假彩色图；(b)真实地物图

Fig. 2.5 The hyperspectral remote sensing image of KSC. (a)False-color image; (b) Ground-truth

### 2.4.3 Indian Pines 数据集

Indian Pines 数据集<sup>[58]</sup>是在 1992 年由 NASA 的 AVIRIS 光谱仪获取的美国印第安纳州西北部一个区域。该影像大小为  $145 \times 145$ ，包含光谱范围从  $0.4\text{--}2.45\ \mu\text{m}$  的 220 个波段，去除因水汽、噪声影响的 20 个波段，实验选取剩余的 200 个波段作为研究对象。该数据集包括玉米、燕麦等 16 种地物，其假彩色图和地面调查样地分布图如图 2.6 所示，括号内为类别对应数目。




图 2.6 Indian Pines 高光谱遥感影像。(a)假彩色图；(b)真实地物图

Fig. 2.6 The hyperspectral remote sensing image of Indian Pines.

(a)False-color image; (b) Ground-truth

#### 2.4.4 Washington DC Mall 数据集

Washington DC Mall 数据集<sup>[59]</sup>是由 HYDICE 传感器获取的华盛顿购物中心。影像大小为  $1208 \times 307$  且包含范围  $0.4 \sim 2.5 \mu\text{m}$  的 210 个波段，剔除受水汽影响部分，余下大小为  $250 \times 307$  的 191 个波段作为实验对象。该数据集包含水、建筑等 6 类地物，其假彩色图和地面真实分布图如图 2.7 所示，括号内为各类地物包含的样本数。




图 2.7 Washington DC Mall 高光谱遥感影像。(a)假彩色图；(b)真实地物图

Fig. 2.7 The hyperspectral remote sensing image of Washington DC Mall.

(a)False-color image; (b) Ground-truth

### 2.5 本章小结

本章首先重点阐述了常用的高光谱影像特征提取算法，总结了经典统计学习算法：PCA、LDA；非线性流形学习算法：ISOMAP、LLE、LE；线性流形学习算法：NPE、LPP；多流形学习算法：MMDA、DMMA；空-谱联合算法：SC-NPE、DSSM，主要介绍这几种特征提取算法的原理思想、实现过程；其次介绍了几种高光谱影像分类评价指标；最后介绍在本文实验中用到的 PaviaU、KSC、Indian Pines 和 Washington DC Mall 高光谱数据集。本章介绍的相关理论和方法为后文的研究奠定了基础。

### 3 基于监督多流形鉴别嵌入的高光谱影像特征提取

#### 3.1 引言

高维数据中可能存在多个不同的属性，且每个属性具有独特的内在流形，若将位于多流形上的数据置于单一流形上描述则会影响数据真实几何结构的研究。研究表明，高光谱数据中存在多个非线性几何结构，即多流形结构。因此，诸如 NPE、LPP 等假设数据均分布于单流形结构的方法不能明确揭示高光谱数据的多流形属性。

为此，本章提出一种新的监督多流形鉴别嵌入 (Supervised Multi-manifold Discriminative Embedding, SMMDE) 学习算法，用以揭示高光谱数据的内在多流形结构。该方法首先利用样本数据的类别标签信息，进行多子流形划分，然后在每一子流形上构建流形内图和流形间图，并在低维嵌入空间中使流形内距离尽可能最小化、流形间距离尽可能最大化，实现流形内数据尽可能聚集、流形间数据尽可能远离，有效提取各低维流形的鉴别特征，改善高光谱影像的地物分类效果。

#### 3.2 相关原理

图嵌入是一种基于图谱理论来描述数据几何特性的理论框架，主要思想是假设高维数据中存在低维流形结构，对有相似性特征的数据点构建相似图，在低维嵌入时，仍保持数据间的几何位置关系不变。实际应用中，图嵌入旨在构造本征图  $G = (\mathbf{X}, \mathbf{W})$  和惩罚图  $G^p = (\mathbf{X}, \mathbf{W}^p)$  来保持数据间的几何特性， $\mathbf{X}$  是原始高维数据，用来表示图的顶点， $\mathbf{W}$  和  $\mathbf{W}^p$  分别表示图  $G$  和图  $G^p$  的相似度权值矩阵。本征图  $G$  揭示同类数据间的相似性，惩罚图  $G^p$  反映异类数据间的近似性。图嵌入的目的是将图的顶点映射为低维向量，采用边权值度量原则保留顶点之间的相似程度。本征图与惩罚图构图方式相同，下面以本征图  $G = (\mathbf{X}, \mathbf{W})$  为例进行说明。

根据图嵌入原理，本征图目标函数定义如下：

$$\begin{aligned}
 & \min \frac{1}{2} \sum_{i,j=1}^N \|\mathbf{y}_i - \mathbf{y}_j\|^2 w_{ij} \\
 & = \frac{1}{2} \sum_{i,j=1}^N (\mathbf{y}_i^T \mathbf{y}_i + \mathbf{y}_j^T \mathbf{y}_j - \mathbf{y}_i^T \mathbf{y}_j - \mathbf{y}_j^T \mathbf{y}_i) \\
 & = \text{tr}(\mathbf{Y}(\mathbf{D} - \mathbf{W})\mathbf{Y}^T) \\
 & = \text{tr}(\mathbf{Y}\mathbf{L}\mathbf{Y}^T) \\
 & s.t. \mathbf{Y}^T \mathbf{D} \mathbf{Y} = \mathbf{I}
 \end{aligned} \tag{3.1}$$

式中， $\mathbf{D}$  为对角矩阵， $\mathbf{L}$  为本征图的拉普拉斯矩阵，且  $\mathbf{L} = \mathbf{D} - \mathbf{W}$ ， $\mathbf{D} = \text{diag} \sum_{i,j=1}^N w_{ij}$ ，

$$\mathbf{W} = \sum_{i,j=1}^N w_{ij} \circ$$

非线性条件下，目标函数为：

$$\min \operatorname{tr}(\mathbf{Y}\mathbf{L}\mathbf{Y}^T) \quad (3.2)$$

线性条件下， $\mathbf{Y} = \mathbf{Z}^T \mathbf{X}$ ，则线性化目标函数表达为：

$$\min \operatorname{tr}(\mathbf{Z}^T \mathbf{X} \mathbf{L} \mathbf{X}^T \mathbf{Z}) \quad (3.3)$$

### 3.3 监督多流形鉴别嵌入

SMMDE 算法的主要思路是发现嵌入于高维空间中的低维多流形结构，以提取鉴别特征。该算法首先利用样本数据的类别标签信息进行子流形划分，并构造流形内图和流形间图，然后通过最小化流形内距离和最大化流形间距离，使得在低维嵌入空间中流形内数据尽可能聚集、流形间数据尽可能发散，进而提升地物分类性能。该算法流程图如图 3.1 所示。

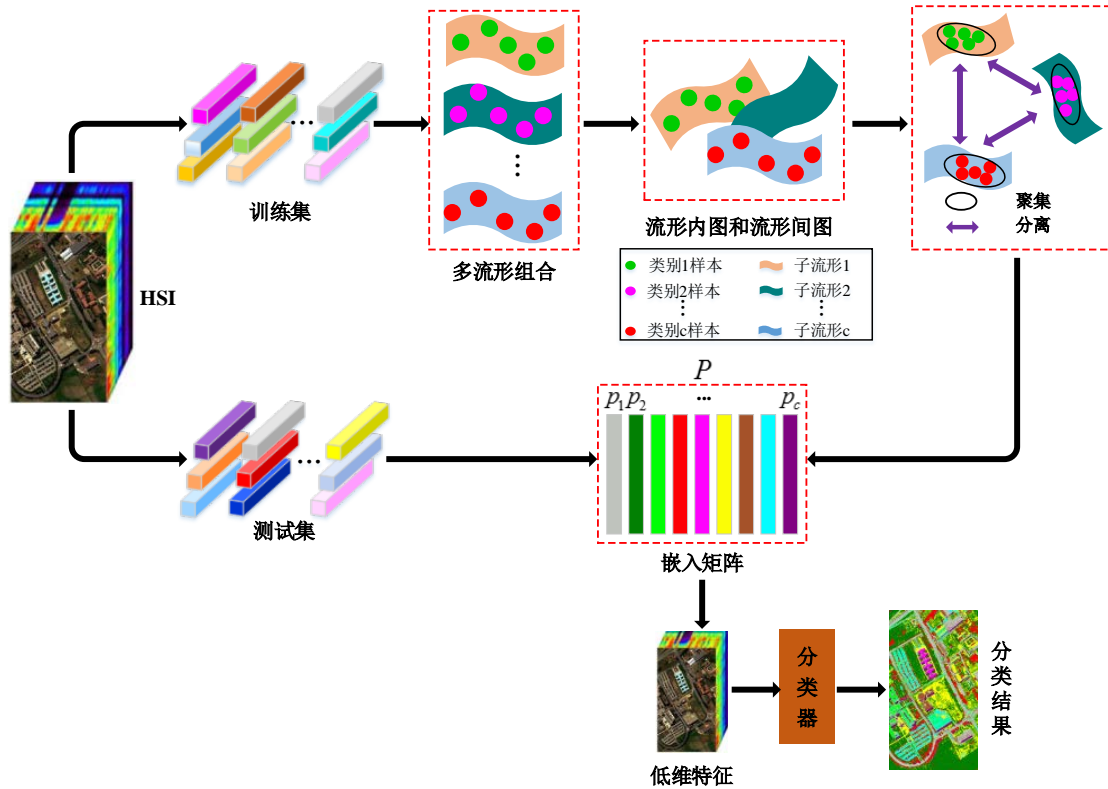


图 3.1 SMMDE 算法流程图

Fig3.1 The process of the SMMDE

在高光谱数据空间中,来自同一地物类别的数据点一般具有相同的光谱特性,可假定来自同一类别的数据点位于同一流形上,不同类别的数据点则来自于不同的流形。因此,根据高光谱训练数据的类别信息,可将其进行多流形划分,并构造流形内图和流形间图。假设高光谱影像中第 $r$ 类地物的子流形表示为 $M_r$ ,则子流形 $M_r$ 的流形内图为 $G_r^{intra}=(V, W_r^{intra})$ ,流形间图为 $G_{q,r}^{inter}=(V, W_{q,r}^{inter})$ ,其中 $V$ 是图的顶点集,  $W_r^{intra}$ 表示流形内权值,  $W_{q,r}^{inter}$ 表示第 $r$ 个流形与第 $q$ 个流形之间的流形间权值。

在流形内图 $G_r^{intra}=(V, W_r^{intra})$ 中,若两点来自同一流形,则用一条边连接这两点,否则不连接。其相似度可用权值 $w_{ij}^{intra}$ 表示,该子流形内权值定义如下:

$$w_{ij}^{intra} = \begin{cases} \exp\left(-\frac{\|V_r(i) - V_r(j)\|^2}{2t_i^2}\right), & l_i = l_j \\ 0, & \text{其他} \end{cases} \quad (3.4)$$

式中,  $t_i = \frac{1}{n_r} \sum_{j=1}^{n_r} \|V_r(i) - V_r(j)\|$ ,  $n_r$ 是第 $r$ 个流形的样本个数,  $V_r \in V$ ,  $V_r$ 是 $V$ 的第 $r$ 个顶点子集。

在流形间图 $G_{q,r}^{inter}=(V, W_{q,r}^{inter})$ 中,若两点来自于不同的子流形,则用一条边连接这两点,否则不连接。其相似度用权值 $w_{ij}^{inter}$ 表示,该流形间权值定义如下:

$$w_{ij}^{inter} = \begin{cases} \exp\left(-\frac{\|V_r(i) - V_q(j)\|^2}{2t_i^2}\right), & l_i \neq l_j \\ 0, & \text{其他} \end{cases} \quad (3.5)$$

式中,  $t_i = \frac{1}{n_r} \sum_{j=1}^{n_r} \|V_r(i) - V_q(j)\|$ ,  $V_q \in V$ ,  $V_q$ 是 $V$ 的第 $q$ 个顶点子集。

在低维空间中,为更有利于高光谱地物分类,则需尽可能保持流形内图的本质特性。来自同一流形的数据在低维嵌入空间应尽可能相近,其目标函数可表示为:

$$\begin{aligned}
J^{\text{intra}}(\mathbf{Z}_r) &= \min \sum_{i,j=1}^{n_r} \|\mathbf{y}_i - \mathbf{y}_j\|^2 w_{ij}^{\text{intra}} \\
&= \sum_{i,j=1}^{n_r} \|\mathbf{Z}_r^T \mathbf{V}_r(i) - \mathbf{Z}_r^T \mathbf{V}_r(j)\|^2 w_{ij}^{\text{intra}} \\
&= \text{tr} \left( \mathbf{Z}_r^T \left[ \sum_{i,j=1}^{n_r} (\mathbf{V}_r(i) - \mathbf{V}_r(j)) (\mathbf{V}_r(i) - \mathbf{V}_r(j))^T w_{ij}^{\text{intra}} \right] \mathbf{Z}_r \right) \\
&= \text{tr}(\mathbf{Z}_r^T D_r^{\text{intra}} \mathbf{Z}_r)
\end{aligned} \tag{3.6}$$

式中,  $D_r^{\text{intra}}$  表示图  $G_r^{\text{intra}} = (\mathbf{V}, \mathbf{W}_r^{\text{intra}})$  内数据点间的距离, 表达如下:

$$D_r^{\text{intra}}(\mathbf{V}_r) = d_r^{\text{intra}}(\mathbf{V}_r(i, j)) + d_r^{\text{intra}}(\mathbf{V}_r(j, i)) \tag{3.7}$$

其中:

$$d_r^{\text{intra}}(\mathbf{V}_r(i, j)) = \sum_{i,j=1}^{n_r} (\mathbf{V}_r(i) - \mathbf{V}_r(j)) (\mathbf{V}_r(i) - \mathbf{V}_r(j))^T w_{ij}^{\text{intra}} \tag{3.8}$$

由权值公式(3.4)可得知, 来自于同一流形上两点的权值不为零, 且在高维空间中距离越近其权值越大。因此, 若在低维嵌入空间中相距较远, 与权值相乘将产生一个较大的惩罚项。因此最小化目标函数(3.8)可以使来自同一个流形的数据点更加聚集。

与此同时, 为使来自不同流形的数据点在低维嵌入空间中具有更好的可分性, 其目标函数表示为:

$$\begin{aligned}
J^{\text{inter}}(\mathbf{Z}_r) &= \max \sum_{i=1}^{n_r} \sum_{j=1}^{n_q} \|\mathbf{y}_i - \mathbf{y}_j\|^2 w_{ij}^{\text{inter}} \\
&= \sum_{i=1}^{n_r} \sum_{j=1}^{n_q} \|\mathbf{Z}_r^T \mathbf{V}_r(i) - \mathbf{Z}_r^T \mathbf{V}_q(j)\|^2 w_{ij}^{\text{inter}} \\
&= \text{tr} \left( \mathbf{Z}_r^T \left[ \sum_{i=1}^{n_r} \sum_{j=1}^{n_q} (\mathbf{V}_r(i) - \mathbf{V}_q(j)) (\mathbf{V}_r(i) - \mathbf{V}_q(j))^T w_{ij}^{\text{inter}} \right] \mathbf{Z}_r \right) \\
&= \text{tr}(\mathbf{Z}_r^T D_{q,r}^{\text{inter}} \mathbf{Z}_r)
\end{aligned} \tag{3.9}$$

式中,  $D^{\text{inter}} = \sum_{q=1, q \neq r}^c D_{q,r}^{\text{inter}}$ ,  $D_{q,r}^{\text{inter}}$  表示图  $G_r^{\text{intra}} = (\mathbf{V}, \mathbf{W}_r^{\text{intra}})$  与图  $G_q^{\text{intra}} = (\mathbf{V}_q, \mathbf{W}_q^{\text{intra}})$  间的距离,

具体表达如下:

$$D_{q,r}^{\text{inter}}(\mathbf{V}_q, \mathbf{V}_r) = d_{q,r}^{\text{inter}}(\mathbf{V}_q, \mathbf{V}_r) + d_{r,q}^{\text{inter}}(\mathbf{V}_r, \mathbf{V}_q) \tag{3.10}$$

$$d_{q,r}^{\text{inter}}(\mathbf{V}_q, \mathbf{V}_r) = \sum_{i=1}^{n_r} \sum_{j=1}^{n_q} (\mathbf{V}_r(i) - \mathbf{V}_q(j)) (\mathbf{V}_r(i) - \mathbf{V}_q(j))^T w_{ij}^{\text{inter}} \tag{3.11}$$

根据权值公式(3.5)可知, 来自不同流形间的两点的权值较小, 且距离越远其权值越小。若在低维嵌入空间中相距较近, 与其相应的权值相乘将产生一个较大的惩罚项。因

此最大化目标函数(3.11)可以使来自不同流形的数据点更加远离，使嵌入特征在低维空间中具有更好的可分性，有利于提升分类性能。

联合式(3.6)和式(3.9)，SMMDE 算法的目标函数可进一步优化如下：

$$\begin{cases} \max \mathbf{Z}_r^T D^{inter} \mathbf{Z}_r \\ \min \mathbf{Z}_r^T D^{intra} \mathbf{Z}_r \end{cases} \quad (3.12)$$

由拉格朗日乘子法，式(3.12)的最优解可表示为：

$$D^{inter} \mathbf{Z}_r = \lambda_r D^{intra} \mathbf{Z}_r \quad (3.13)$$

根据广义特征值问题，求取式(3.13)的特征值，并且按照从大到小的顺序，取前  $d$  个特征值对应的特征向量为投影向量  $\mathbf{Z}_r = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ ，同理，求取每个子流形的投影向量，组成一组最佳嵌入矩阵  $\mathbf{Z} = [\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_c]$ 。

为具体分析 SMMDE 的运行过程，用  $O$  表示该算法的计算复杂度。则该算法的计算复杂度主要包括如下几部分：流形内距离  $D_r^{intra}$  和流形间距离  $D_{q,r}^{inter}$  的计算复杂度为  $O(N^3)$ ，式(3.12)目标函数求解的计算复杂度为  $O(DN^2)$ ，式(3.13)特征值问题计算复杂度为  $O(D^3)$ 。因此，SMMDE 算法的总计算复杂度为  $O(N^3 + D^3 + DN^2)$ ，该算法的运行效率主要取决于高光谱影像的波段数及训练样本数。

表 3.1 SMMDE 算法步骤

Table 3.1 Steps of SMMDE

<b>Input:</b> 高光谱遥感数据集 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \in \mathbf{R}^{D \times N}$ ， $\mathbf{x}_i$ 的类别标签 $l_i \in \{1, 2, \dots, c\}$ ，嵌入维度 $d (d \ll D)$ 。
<b>Output:</b> 投影矩阵 $\mathbf{Z} = [\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_c] \in \mathbf{R}^{D \times d}$ 。
<b>Step 1:</b> 根据标签信息将训练样本数据划分为不同的流形， $M = [M_1, M_2, \dots, M_c]$ ；
<b>Step 2:</b> 构造流形内图 $G_r^{intra} = (\mathbf{V}, \mathbf{W}_r^{intra})$ ，根据公式(3.4)求取权值 $w_{ij}^{intra}$ ；
<b>Step 3:</b> 构造流形间图 $G_{q,r}^{inter} = (\mathbf{V}, \mathbf{W}_{q,r}^{inter})$ ，根据公式(3.5)求取权值 $w_{ij}^{inter}$ ；
<b>Step 4:</b> 由 $D_r^{intra}(\mathbf{V}_r) = d_r^{intra}(\mathbf{V}_r(i, j)) + d_r^{intra}(\mathbf{V}_r(j, i))$ 计算流形内距离；
<b>Step 5:</b> 由 $D_{q,r}^{inter}(\mathbf{V}_q, \mathbf{V}_r) = d_{q,r}^{inter}(\mathbf{V}_q, \mathbf{V}_r) + d_{r,q}^{inter}(\mathbf{V}_r, \mathbf{V}_q)$ 计算流形间距离；
<b>Step 6:</b> 计算 $D^{inter} \mathbf{Z}_r = \lambda_r D^{intra} \mathbf{Z}_r$ 的特征值，每个流形选取前 $d$ 个最大的特征值对应的特征向量组成投影向量 $\mathbf{Z}_r = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ ，最佳嵌入矩阵 $\mathbf{Z} = [\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_c]$ ， $\mathbf{Z}_i \in \mathbf{R}^{D \times d}$ 。

### 3.4 实验结果与分析

为验证本章所提算法的优良性，特选取两个高光谱遥感影像数据集：PaviaU 和 KSC 进行实验。

### 3.4.1 实验设置

在实验中,将高光谱数据集随机划分为训练集和测试集,并采用总体分类精度(OA)、平均分类精度(AA)和  $Kappa$  系数三个指标来评价不同算法的性能。

为验证本文提出的 SMMDE 算法的分类性能,选取 RAW、PCA、NPE、LPP、LDA、MFA、LGSFA、SMML、M-LPP (Multi-manifold Learning based on LPP, M-LPP)<sup>[60]</sup>、M-LLGPE 进行实验对比,其中 RAW 表示直接用分类器对样本进行分类,最后三种为多流形学习方法。在每种实验条件下,为使各种算法达到较优的分类结果,采用交叉验证反复对各算法参数进行调试。实验中, NPE、LPP、MFA、MLPP、M-LLGPE 的近邻数  $k$  设置为 5, LGSFA 的近邻数设置为 9, LDA 的嵌入维数设置为  $c-1$ ,  $c$  为类别数。利用各算法进行学习得到低维嵌入特征后,采用分类器进行分类。M-LPP、M-LLGPE 方法采用重构误差分类器(Reconstruction Error-based Classifier, REC)<sup>[50]</sup>进行分类,其他算法则采用最近邻分类器(1-Nearest Neighbor, 1-NN)<sup>[61]</sup>进行分类。

### 3.4.2 PaviaU 数据集实验

在实验中,为研究不同嵌入维数对各算法的影响,从每类地物中随机选取 30 个数据进行训练,其余样本进行测试。图 3.2 为各算法进行 10 次实验后的平均分类精度。

从图 3.2 中可得知,随着嵌入维数的增加,各算法的分类精度逐渐提高,这是因为维数越高包含的信息越丰富,越有利于分类。但是嵌入维数增加到一定程度后,大部分算法分类精度趋于稳定,其原因是嵌入特征中蕴含的信息趋于饱和。相比于其他算法,本文 SMMDE 算法的分类精度在各维数下都优于其他算法,且能快速达到最佳分类性能,这是因为该算法可以更好地表征数据内在多流形结构,获取低维鉴别特征。为使各算法都能达到较好的分类性能,实验中除 LDA 外,其余算法的嵌入维度均设置为 20。

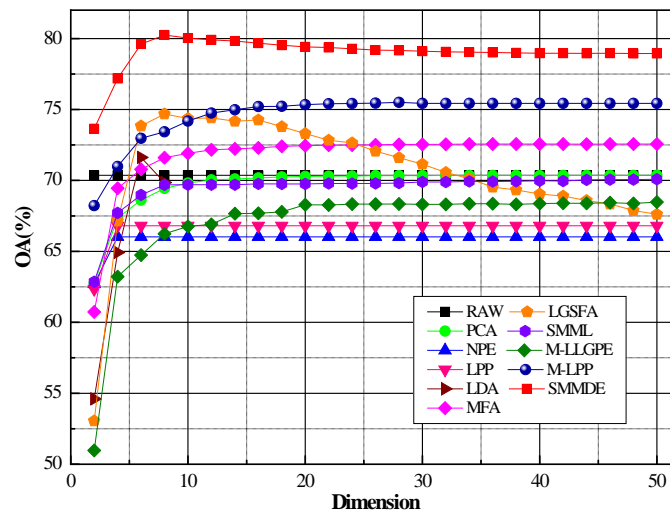


图 3.2 PaviaU 数据集上各算法在各维度下的总体分类精度

Fig.3.2 The overall accuracy of different dimensions by each methods on PaviaU



实验中, 为验证各类算法针对不同训练样本条件的分类性能, 从 PaviaU 数据集每类地物中随机选取  $n_i$  个数据点作为训练样本, 其余作为测试样本。表 3.2 为各算法在不同训练样本下 10 次实验的平均分类结果。

表 3.2 不同算法在 PaviaU 数据集上的分类精度( $OA \pm \text{std}(\%)(Kappa)$ )

Table 3.2 The ( $OA \pm \text{std}(\%)(Kappa)$ ) of different methods on PaviaU				
算法	$n_i=10$	$n_i=20$	$n_i=30$	$n_i=40$
RAW	61.79 $\pm$ 3.29(0.531)	67.37 $\pm$ 1.55(0.592)	70.47 $\pm$ 1.67(0.628)	71.40 $\pm$ 1.74(0.638)
PCA	61.78 $\pm$ 3.29(0.531)	67.31 $\pm$ 1.55(0.591)	70.37 $\pm$ 1.68(0.627)	71.31 $\pm$ 1.78(0.637)
NPE	60.10 $\pm$ 3.27(0.511)	63.26 $\pm$ 1.91(0.545)	67.76 $\pm$ 2.20(0.596)	69.46 $\pm$ 1.32(0.615)
LPP	60.63 $\pm$ 3.09(0.517)	63.97 $\pm$ 2.24(0.554)	66.11 $\pm$ 2.52(0.577)	70.40 $\pm$ 1.41(0.627)
LDA	61.05 $\pm$ 2.79(0.523)	64.32 $\pm$ 2.33(0.557)	67.48 $\pm$ 1.84(0.588)	70.10 $\pm$ 1.67(0.621)
MFA	64.15 $\pm$ 2.92(0.558)	69.45 $\pm$ 1.76(0.617)	72.51 $\pm$ 1.34(0.652)	73.73 $\pm$ 1.54(0.666)
LGSFA	56.13 $\pm$ 5.22(0.461)	67.50 $\pm$ 1.50(0.590)	72.95 $\pm$ 2.34(0.657)	74.14 $\pm$ 2.49(0.671)
SMML	61.63 $\pm$ 3.32(0.529)	68.72 $\pm$ 1.57(0.606)	70.02 $\pm$ 1.73(0.623)	71.05 $\pm$ 1.71(0.634)
M-LLGPE	64.14 $\pm$ 7.07(0.556)	67.32 $\pm$ 7.61(0.591)	68.04 $\pm$ 4.27(0.599)	72.76 $\pm$ 2.62(0.656)
M-LPP	68.73 $\pm$ 3.66(0.609)	73.91 $\pm$ 2.85(0.673)	75.67 $\pm$ 1.71(0.694)	78.23 $\pm$ 2.22(0.722)
SMMDE	<b>70.69</b> $\pm$ 1.75(0.632)	<b>76.25</b> $\pm$ 1.72(0.698)	<b>79.69</b> $\pm$ 1.07(0.740)	<b>81.47</b> $\pm$ 1.45(0.752)

由表 3.2 可知, 随着训练样本数增加, 各算法的分类精度和  $Kappa$  系数都有明显提升, 这是因为样本数越多, 蕴含信息就越丰富, 越有利于进行特征提取。在相同实验条件下, 本文提出的 SMMDE 算法比其他算法分类精度都高, 具体分析如下: PCA、NPE、LPP 等非监督学习方法未能充分利用样本数据的类别信息, 其分类性能受限; MFA 和 LGSFA 等监督学习方法, 其分类性能虽有不同程度的提升, 但其没有充分表征数据的潜在多流形结构, 不能充分提取鉴别特征; M-LLGPE 等多流形算法分类结果相对其他方法分类精度均有明显的提升, 但是对小样本的鉴别能力不足, 实际应用受限; 本文 SMMDE 方法充分利用数据的多流形结构构造流形内图和流形间图, 有效增强了流形内数据聚集性和流形间数据分离性, 提取低维鉴别特征, 在不同的训练条件下均取得了最佳的分类性能, 特别是小样本下效果更明显。

为对比各算法对每类地物的分类效果, 从 PaviaU 数据集中随机选取 2% 作为训练样本, 剩下的样本用于测试。表 3.3 为每类地物的分类精度、总体分类精度和  $Kappa$  系数, 图 3.3 为不同算法相应的分类结果图。

表 3.3 各算法对 PaviaU 数据集上每类地物的分类精度和分类结果(%)

Table 3.3 Classification accuracy of each class on PaviaU by different methods(%)											
类别	RAW	PCA	NPE	LPP	LDA	MFA	LGSFA	SMML	M-LLGPE	M-LPP	SMMDE
1	80.42	80.34	78.82	79.50	79.11	81.76	82.18	81.33	75.11	<b>87.76</b>	83.96

2	90.50	90.26	82.99	83.21	83.88	91.31	<b>96.76</b>	89.55	96.45	90.86	96.21
3	52.94	53.18	45.89	47.10	48.51	61.83	59.01	52.79	49.78	69.08	<b>75.79</b>
4	74.92	74.89	73.59	73.52	73.86	72.79	87.94	75.29	54.11	<b>94.73</b>	79.39
5	98.78	98.78	98.63	98.86	98.33	98.93	99.62	98.71	<b>99.84</b>	99.77	99.54
6	58.42	58.42	48.23	48.39	47.66	61.85	50.67	56.71	46.51	<b>82.30</b>	74.94
7	83.80	84.03	60.86	61.70	65.61	87.10	80.81	83.42	76.13	66.38	<b>92.40</b>
8	75.61	75.49	71.92	72.42	72.09	76.74	69.15	75.91	58.06	55.26	<b>77.25</b>
9	99.89	99.89	99.89	99.89	99.89	<b>100</b>	99.24	99.89	25.32	99.35	99.89
AA	79.48	79.48	73.43	73.85	74.33	81.37	80.60	79.29	64.59	82.84	<b>86.60</b>
OA	81.19	81.08	74.99	75.34	75.66	82.64	83.87	80.74	76.55	85.23	<b>88.04</b>
Kappa	0.749	0.747	0.668	0.673	0.677	0.768	0.782	0.743	0.677	0.806	<b>0.840</b>

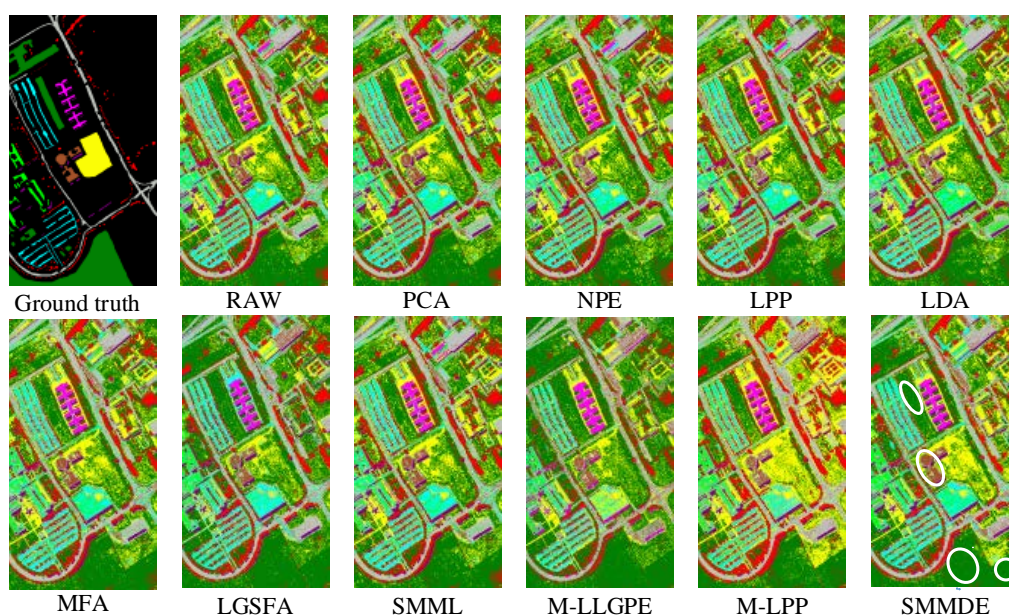


图 3.3 各算法在 PaviaU 数据集上的分类图

Fig.3.3 Classification maps of different methods on PaviaU

由表 3.3 可知，与其他算法相比，SMMDE 算法在大部分地物中都能达到较好的分类效果，且其总体分类精度、平均分类精度和 *Kappa* 系数均为最高，说明 SMMDE 算法能有效地揭示高光谱影像的内在多流形结构，更好地提取鉴别特征，进而有效提高分类性能。在图 3.3 中，SMMDE 算法得到的分类图更为光滑，特别是白色圆圈标记的“Gravel”、“Bitumen”等地物类别上效果尤为明显。

### 3.4.3 KSC 数据集实验

在实验中，为研究不同算法在不同嵌入维度下的分类性能，从 KSC 数据集每类地物中随机选取 30 个数据进行实验，图 3.4 给出了各算法在不同嵌入维度下重复 10 次实验的分类结果。

由图 3.4 可得，各算法 OA 值随着嵌入维度的增加而不断提高，而后趋于稳定。与

此同时, SMMDE 算法在大多数嵌入维数中其分类精度优于其他算法, 这是表明本文提出的 SMMDE 算法能更有效发现高光谱数据中的多流形结构, 提取低维鉴别特征。在后续实验中, LDA 算法的嵌入维数为  $c-1$ , 其他算法的嵌入维数均设置为 20, 以保证各算法获得较好的分类效果。

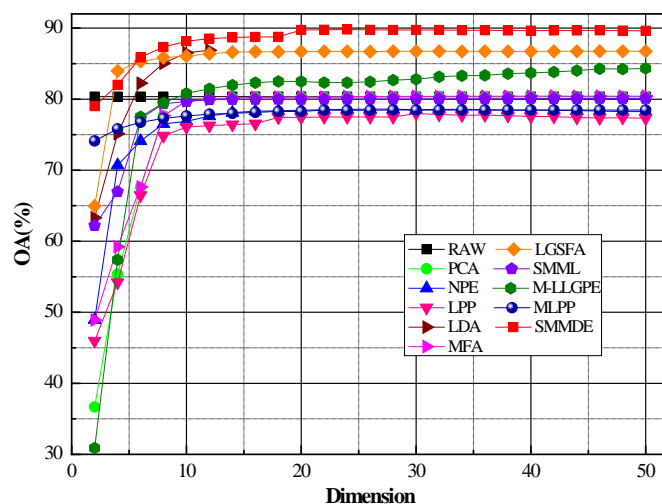


图 3.4 KSC 数据集上各算法在各嵌入维度下的总体分类精度

Fig.3.4 The overall accuracy of different dimensions by each methods on KSC

为验证各类算法在不同训练样本情况下的分类性能, 实验中从 KSC 数据集每类地物中随机选取  $n_i$  个数据点作为训练样本, 其余作为测试样本进行实验。表 3.4 为各类算法在不同训练样本下进行 10 次重复实验的平均总体分类精度及其标准差、Kappa 系数。

表 3.4 不同算法在 KSC 数据集上的分类精度( $OA \pm \text{std}(\%)$ )(Kappa))

Table 3.4 The ( $OA \pm \text{std}(\%)$ )(Kappa)) of different methods on KSC				
算法	$n_i=10$	$n_i=20$	$n_i=30$	$n_i=40$
RAW	72.96 $\pm$ 1.33(0.699)	78.30 $\pm$ 1.04(0.758)	80.68 $\pm$ 0.98(0.784)	82.14 $\pm$ 0.72(0.800)
PCA	72.92 $\pm$ 1.34(0.699)	78.21 $\pm$ 1.04(0.757)	80.59 $\pm$ 1.02(0.783)	82.00 $\pm$ 0.67(0.799)
NPE	53.36 $\pm$ 5.07(0.485)	70.56 $\pm$ 2.05(0.673)	78.09 $\pm$ 1.21(0.756)	81.65 $\pm$ 1.15(0.795)
LPP	52.76 $\pm$ 3.84(0.479)	65.00 $\pm$ 1.81(0.612)	76.65 $\pm$ 1.41(0.740)	81.44 $\pm$ 1.57(0.793)
LDA	61.87 $\pm$ 3.30(0.580)	79.42 $\pm$ 1.17(0.771)	86.37 $\pm$ 0.69(0.848)	88.78 $\pm$ 0.60(0.874)
MFA	72.98 $\pm$ 1.41(0.700)	78.23 $\pm$ 1.04(0.758)	80.59 $\pm$ 1.02(0.783)	82.07 $\pm$ 0.63(0.780)
LGSFA	77.44 $\pm$ 1.29(0.749)	84.27 $\pm$ 0.82(0.825)	86.97 $\pm$ 0.76(0.854)	87.65 $\pm$ 0.59(0.862)
SMML	72.64 $\pm$ 1.33(0.696)	77.90 $\pm$ 1.21(0.754)	80.28 $\pm$ 1.02(0.780)	81.78 $\pm$ 0.76(0.796)
M-LLGPE	76.98 $\pm$ 2.81(0.744)	83.62 $\pm$ 1.78(0.817)	83.87 $\pm$ 1.54(0.820)	86.29 $\pm$ 0.73(0.847)
M-LPP	73.73 $\pm$ 2.29(0.709)	77.38 $\pm$ 2.27(0.748)	79.58 $\pm$ 3.58(0.772)	89.12 $\pm$ 0.86(0.878)
SMMDE	<b>82.50<math>\pm</math>1.34(0.806)</b>	<b>87.42<math>\pm</math>0.86(0.861)</b>	<b>89.98<math>\pm</math>0.90(0.887)</b>	<b>90.75<math>\pm</math>0.61(0.896)</b>

通过分析表 3.4 可知, 各算法的分类精度随训练样本数增加而提高, 同时监督流形学习方法的分类性能要优于非监督学习方法。在不同实验条件下, SMMDE 的分类效果均优于其他算法, 在训练样本较少时尤为明显。这是由于 SMMDE 方法通过对划分后的子流形数据进行学习, 引入图嵌入框架, 分别构造流形内图和流形间图, 根据同一子流形和不同子流形间的数据之间的相似性, 在低维嵌入空间使流形内数据尽可能聚集、流形间数据尽可能分散, 改善了数据的可分性, 使不同地物类别的嵌入特征间距最大化, 有效提升分类精度, 更有利于实际应用。

为进一步表明 SMMDE 算法对各类地物的特征提取能力, 从 KSC 数据集中随机选取 2% 样本用于训练, 其余样本作为测试进行研究。表 3.5 为每类地物的分类精度、总体分类精度和 *Kappa* 系数。图 3.5 为不同算法学习后的分类效果图。

表 3.5 各算法对 KSC 数据集上每类地物的分类精度和分类结果(%)

Table 3.5 Classification accuracy of each class on KSC by different methods(%)

类别	RAW	PCA	NPE	LPP	LDA	MFA	LGSFA	SMML	M-LLGPE	M-LPP	SMMDE
1	79.08	78.95	49.33	27.34	66.08	78.95	80.69	78.82	83.38	<b>89.54</b>	86.86
2	66.52	66.52	32.62	22.31	57.08	66.52	75.96	67.81	87.55	<b>87.12</b>	78.11
3	60.57	60.16	20.32	20.32	42.68	59.75	73.17	60.57	59.75	48.78	<b>73.17</b>
4	37.19	37.19	16.12	9.09	31.82	36.77	40.49	36.36	54.96	52.48	<b>60.33</b>
5	62.91	62.91	25.83	19.86	31.79	62.91	63.57	63.57	58.94	<b>68.87</b>	62.91
6	36.07	36.98	16.89	22.37	15.52	36.53	41.55	36.53	<b>49.77</b>	45.66	42.92
7	76.84	77.89	55.79	35.78	49.47	76.84	81.05	76.84	77.89	92.63	<b>93.68</b>
8	67.69	67.69	38.95	27.55	50.59	67.69	72.21	67.69	82.42	<b>93.58</b>	79.57
9	85.88	86.27	38.23	40.00	55.09	86.08	89.60	86.08	72.55	<b>97.84</b>	96.86
10	75.38	75.12	57.61	28.93	76.14	75.13	81.72	75.89	77.15	<b>88.32</b>	87.06
11	90.46	90.71	81.42	74.32	66.01	90.71	93.64	90.46	<b>99.75</b>	98.53	94.62
12	72.82	72.82	28.80	60.04	45.23	72.82	77.28	72.62	46.04	6.69	<b>79.31</b>
13	97.79	97.79	89.32	96.81	88.76	97.79	97.90	97.79	97.79	<b>99.01</b>	<b>99.01</b>
AA	69.94	70.08	42.40	37.29	52.02	69.88	74.53	70.08	72.92	74.54	<b>79.57</b>
OA	76.33	76.39	50.01	46.46	59.80	76.30	80.06	76.39	77.40	78.66	<b>84.53</b>
<i>Kappa</i>	0.737	0.738	0.446	0.410	0.556	0.736	0.778	0.737	0.749	0.762	<b>0.828</b>



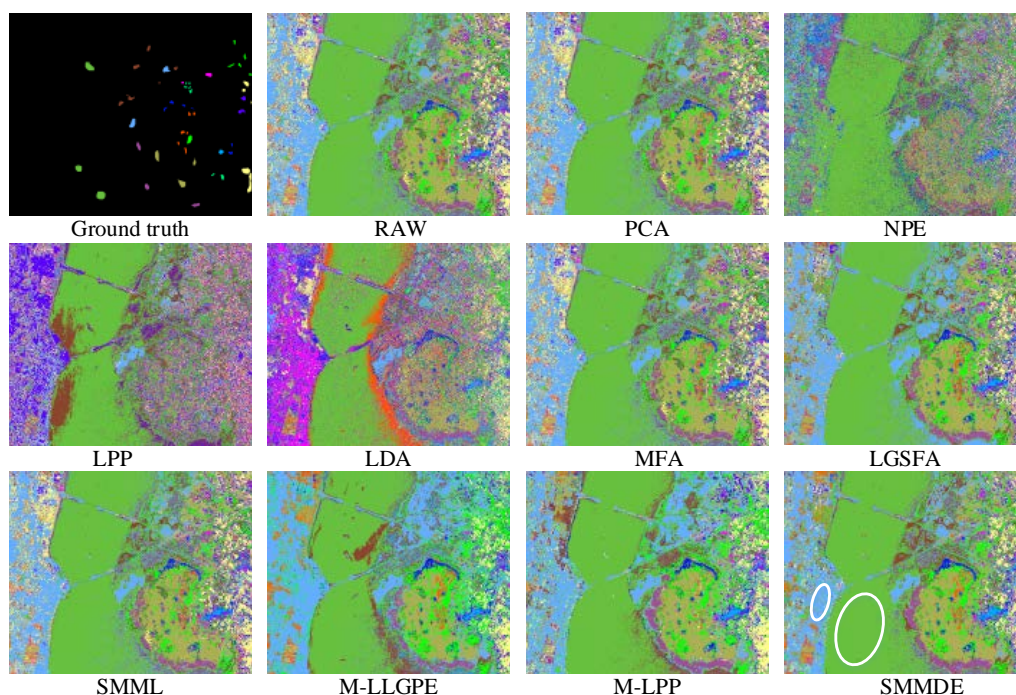


图 3.5 各算法在 KSC 数据集上的分类图

Fig.3.5 Classification maps of different methods on KSC

由表 3.5 可知，相比于其他算法，SMMDE 在多半地物类别中都能获得最佳分类效果，且获得的总体分类精度、平均分类精度及  $Kappa$  系数最高，这表明 SMMDE 能充分揭示高光谱数据的内蕴特性，有利于高光谱数据地物分类。在图 3.5 中，SMMDE 算法得到的分类图更平滑，特别是白色圈标记的“Water”、“Hardwood swamp”等地物类别更为明显。

### 3.4.4 实验结论

通过在 PaviaU 和 KSC 高光谱数据集上的实验分析，可得如下结论：

① 在各种实验条件下，本章所提出的 SMMDE 算法分类精度都高于 RAW、PCA、NPE、LPP、LDA、MFA、LGSFA、SMML、M-LPP 和 M-LLGPE。主要是由于 SMMDE 是一种监督多流形学习方法，不仅揭示了高光谱数据的内在多流形结构，而且增强了类内聚集性和类间分散性。

② 大部分情况下，监督学习算法比非监督学习算法效果好，因为监督学习算法可以充分利用样本的标签信息，且随样本增多，蕴含的类别信息越丰富，提升了有用信息的表达。此外，SMMDE 能够充分利用数据的类别信息，进行流形内和流形间的特征提取，使得特征表达更完善，进而提高分类性能。

③ 对比多流形学习算法 SMML、M-LPP 和 M-LLGPE，SMMDE 分类性能更突出。因为 SMMDE 通过对每个子流形学习，引入图嵌入，在子流形上构图，表征每个子流形的结构特征，并定义流形内距离和流形间距离，进一步强化了数据间的可分性，提高了

分类精度。

④ 大多数情况下，SMMDE 的分类效果都较其他算法好，小样本下更为突出，且从分类结果图可以看出，SMMDE 算法整体相对更平滑。在 PaviaU 和 KSC 选取 2% 的训练样本，其总体分类精度可分别提高到 86.60% 和 79.57%，明显改善了影像地物分类性能。

### 3.5 本章小结

针对目前单流形学习方法不能有效发现高维数据中的多流形结构，本章提出了一种监督多流形鉴别嵌入特征提取算法，并应用于高光谱数据地物分类。该方法将每类地物视为一个子流形，并利用样本数据的类别标签进行子流形划分，在此基础上通过构造类内流形图和类间流形图，并在低维嵌入空间中使流形内距离尽可能最小化、流形间距离尽可能最大化，使流形内数据聚集、流形间数据分散，增加不同地物间可分性，有效提取鉴别特征，进而改善分类效果。在 PaviaU 和 KSC 高光谱数据集上的实验结果表明，本文提出的 SMMDE 算法与其他单流形、多流形算法相比，分类精度更高，分类效果更明显。

## 4 基于监督空间正则化流形鉴别分析的高光谱影像特征提取

### 4.1 引言

高光谱影像不仅含有光谱信息,在空间域仍具有富足的描述像元几何位置的空间特征。在高光谱影像分类过程中,若单纯的利用光谱信息可能会造成地物错分现象,研究表明,地物空间特征可以弥补仅依靠光谱信息分类的不足,可通过加入空间信息抑制光谱的不确定性,从而提高地物分类性能。

本章结合流形学习理论及影像中的空-谱信息,提出一种新的流形学习特征提取算法,即监督空间正则化流形鉴别分析 (Supervised Spatial Regularized Manifold Discriminant Analysis, SSRMDA) 算法。该算法利用图嵌入模型分别在光谱域与空间域构造光谱图和空间图,并采用流形学习揭示高光谱数据的内在结构,进而提取有效的鉴别信息,增强地物分类效果。

### 4.2 相关原理

2003 年, Ren 等<sup>[62]</sup> 提出了一种图像分割技术,即超像素。它是指一系列具有相似特征(颜色、纹理、亮度等)且空间位置相邻的像素构成的不规则局部图像块区域,其大小和形状可以根据图像不同的局部空间结构自适应调整,从而尽可能地保留有用信息,特别是边缘保持性好。它将一些具有相似性特征的像素“聚合”起来,通过较少的超像素来替代大量的像素以描述图像特征,从而生成超像素图像。超像素分割可以充分发掘图像中的空间信息,减少冗余,在图像后续处理阶段降低了复杂性。2011 年, Liu 等<sup>[63]</sup> 提出了一种基于图论的熵率超像素(Entropy Rate Superpixel, ERS)分割方法,该方法有利于获得结构一致、紧凑的聚类区域。由于 ERS 的有效分割,被一些研究学者用于提取高光谱影像空间特征<sup>[64, 65]</sup>。

ERS 是一种将图像映射到图  $G=(\mathbf{X}, E)$  的基于图论的分割方法,  $\mathbf{X}$  表示顶点集,  $E$  表示边集,每个像素表示图的一个顶点,记为  $\mathbf{x}_i \in \mathbf{X}$ ,  $e_{ij}$  表示连接顶点  $\mathbf{x}_i$  与  $\mathbf{x}_j$  之间的边,其边权值为  $w_{ij}$ , 表示顶点  $\mathbf{x}_i$  与  $\mathbf{x}_j$  之间的相似度。ERS 的目标函数定义如下:

$$\max F(A) = H(A) + \lambda B(A) \quad (4.1)$$

其中  $\lambda \geq 0$  是平衡因子,  $H(A)$  是图上随机游走熵率(以下简称熵率),  $B(A)$  为平衡项。下面分别介绍:

① 熵率。ERS 的目的是选择边缘子集  $A: A \in E$ , 得到  $K_A$  个子图构成图  $G'=(\mathbf{X}, A)$ 。为获得结构均匀、紧凑的聚类区域,随机游走转移概率定义如下:

$$p_{ij}(A) = \begin{cases} \frac{w_{ij}}{w_i}, & i \neq j \text{ 且 } e_{ij} \in A \\ 0, & i \neq j \text{ 且 } e_{ij} \notin A \\ \frac{\sum_j w_{ij}}{w_i}, & i = j \text{ 且 } w_{ij} \in A \end{cases} \quad (4.2)$$

由此可得  $G' = (\mathbf{X}, A)$  上的熵率函数为:

$$H(A) = -\sum_i \mu_i \sum_j p_{ij}(A) \log(p_{ij}(A)) \quad (4.3)$$

式中,  $\mu$  代表随机过程的静态分布,  $\mu_i = w_i / w_T$ , 且  $w_T = \sum_{i=1}^{|\mathbf{X}|} w_i$  为归一化常量,  $|\mathbf{X}|$  表示图的顶点数。

② 平衡项。将原图分割为:  $S_A = \{s_1, s_2, \dots, s_{N_A}\}$ ,  $N_A$  是原图划分后的子集个数,  $Q_A$  为聚类分布, 为得到大小相似的集群, 有:

$$p_{Q_A}(i) = \frac{|s_i|}{|\mathbf{X}|}, \quad i = \{1, \dots, N_A\} \quad (4.4)$$

则平衡项函数表达为:

$$B(A) = H(Q_A) - N_A = -\sum_j p_{Q_A}(i) \log(p_{Q_A}(i)) - N_A \quad (4.5)$$

### 4.3 监督空间正则化流形鉴别分析

针对传统的高光谱影像特征提取算法通常仅依赖光谱信息而忽略影像空间结构信息的不足, 本文提出了一种监督空间正则化流形鉴别分析(SSRMDA)算法。该算法首先将训练样本中的每个点作为顶点, 每个顶点通过相应的光谱信息描述, 从而构造光谱域上的类内图和类间图; 其次, 通过熵率超像素(ERS)方法将原始高光谱影像分割为多个超像素块, 以超像素块内的每个像素点为顶点, 构造空域类内图以描述空间特征并作为正则项加入目标函数, 加强类内数据聚集性; 最后, 通过正则化参数来平衡光谱特征和空间特征的融合度, 使用图嵌入模型求取低维嵌入矩阵, 保持高维空间中的低维流形结构不变, 提取鉴别特征, 实现地物分类。该算法流程图如图 4.1 所示:



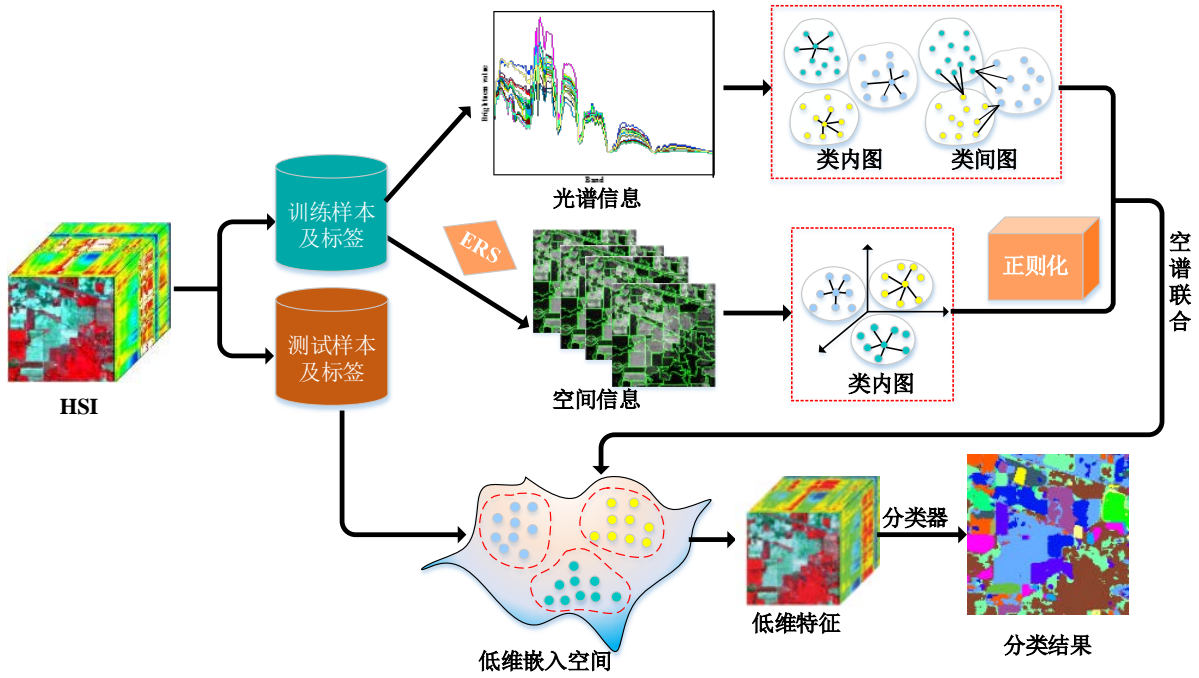


图 4.1 SSRMDA 算法流程图

Fig. 4.1 The process of the SSRMDA

下面对该算法进行具体介绍：

#### ① 谱域表达

构造类内图  $G^w = (\mathbf{X}, \mathbf{W}^w)$ ， $\mathbf{X}$  表示图的顶点集，若顶点  $\mathbf{x}_i$  与  $\mathbf{x}_j$  来自同类数据且  $\mathbf{x}_j$  是  $\mathbf{x}_i$  的  $K_w$  近邻，则在两点之间连一条边，否则  $\mathbf{x}_i$  与  $\mathbf{x}_j$  无连接边。边权值为  $w_{ij}^w$ ，描述了两点之间的相似关系，定义如下：

$$w_{ij}^w = \begin{cases} \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma_i^2}\right), & \mathbf{x}_i \in N_{K_w}(\mathbf{x}_j) \text{ or } \mathbf{x}_j \in N_{K_w}(\mathbf{x}_i) \text{ and } l_i = l_j \\ 0, & \text{otherwise} \end{cases} \quad (4.6)$$

式中， $\sigma_i = \frac{1}{N} \sum_{j=1}^N \|\mathbf{x}_i - \mathbf{x}_j\|$ ， $N_{K_w}(\mathbf{x}_i)$  和  $N_{K_w}(\mathbf{x}_j)$  分别属于  $\mathbf{x}_i$ 、 $\mathbf{x}_j$  的类内  $K_w$  近邻。

构造类间图  $G^b = (\mathbf{X}, \mathbf{W}^b)$ ， $\mathbf{X}$  代表图顶点集，若  $\mathbf{x}_i$  与  $\mathbf{x}_j$  是来自非同类数据的  $K_b$  近邻，则用一条边连接两点，否则无连接，反映两点相似性的边权值  $w_{ij}^b$  定义如下：

$$w_{ij}^b = \begin{cases} \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma_i^2}\right), & \mathbf{x}_i \in N_{K_b}(\mathbf{x}_j) \text{ or } \mathbf{x}_j \in N_{K_b}(\mathbf{x}_i) \text{ and } l_i \neq l_j \\ 0, & \text{otherwise} \end{cases} \quad (4.7)$$

式中,  $N_{K_b}(\mathbf{x}_i)$  与  $N_{K_b}(\mathbf{x}_j)$  分别是  $\mathbf{x}_i$ 、 $\mathbf{x}_j$  的类间  $K_b$  近邻。

## ② 空间正则化

对给定的高光谱数据  $\mathbf{X} \in \mathbf{R}^{D \times N}$ , 利用 ERS 对其进行分割处理, 可得到超像素集  $S = \{s_1, s_2, \dots, s_{N_A}\}$ ,  $N_A$  是超像素个数。如图 4.2 所示, 对比超像素分割图与真实地物图, 可看出, 同一个超像素内的像素通常来自于同一地物类别。因此, 本文利用 ERS 处理后的空间信息构造空域类内图, 并作为正则项, 以强化类内数据的聚集性。




图 4.2 ERS 分割图与真实图。(a)分割图; (b)真实图

Fig. 4.2 Segmentation map and ground-truth map.

(a)Superpixel segmentation map; (b)Ground-truth map

构造空间正则化类内图  $G^{sw} = (\mathbf{X}, \mathbf{W}^{sw})$ ,  $\mathbf{X}$  是图顶点, 若两点  $\mathbf{x}_i, \mathbf{x}_j \in s_i$ , 且  $\mathbf{x}_j$  是  $\mathbf{x}_i$  的  $K_{sw}$  近邻, 则在两点之间连一条边, 否则, 两点间无连接边。反映该两点近似程度的边权值  $w_{ij}^{sw}$  定义如下:

$$w_{ij}^{sw} = \begin{cases} \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma_i^2}\right), & \mathbf{x}_i \in N_{K_{sw}}(\mathbf{x}_j) \text{ or } \mathbf{x}_j \in N_{K_{sw}}(\mathbf{x}_i) \text{ and } l_i = l_j \\ 0, & \text{otherwise} \end{cases} \quad (4.8)$$

式中,  $\sigma_i = \frac{1}{n} \sum_{\mathbf{x}_j \in s_i} \|\mathbf{x}_i - \mathbf{x}_j\|$ ,  $n$  是超像素  $s_i$  内像素总数,  $N_{K_{sw}}(\mathbf{x}_i)$  与  $N_{K_{sw}}(\mathbf{x}_j)$  分别是  $\mathbf{x}_i$ 、 $\mathbf{x}_j$  的空间正则化类内  $K_{sw}$  近邻。

### ③ 空-谱联合低维嵌入

在低维空间中, 使类内数据尽可能地聚集, 类间数据尽可能远离, 以增加数据的可分性, 则算法目标函数表达如下:

$$\begin{aligned} J_1 &= \min \left\{ (1-\alpha) \sum_{i,j=1}^N \|\mathbf{Z}^T \mathbf{x}_i - \mathbf{Z}^T \mathbf{x}_j\|^2 w_{ij}^w + \alpha \frac{1}{N_A} \sum_{t=1}^{N_A} \sum_{\mathbf{x}_i, \mathbf{x}_j \in s_t} \|\mathbf{Z}^T \mathbf{x}_i - \mathbf{Z}^T \mathbf{x}_j\|^2 w_{ij}^{sw} \right\} \\ &= \text{tr} \left\{ (1-\alpha) \mathbf{Z}^T \mathbf{X} (\mathbf{D}^w - \mathbf{W}^w) \mathbf{X}^T \mathbf{Z} + \alpha \frac{1}{N_A} \sum_{t=1}^{N_A} \mathbf{Z}^T \mathbf{X}_t (\mathbf{D}^{sw} - \mathbf{W}^{sw}) \mathbf{X}_t^T \mathbf{Z} \right\} \quad (4.9) \\ &= \text{tr} \left\{ (1-\alpha) \mathbf{Z}^T \mathbf{X} \mathbf{L}^w \mathbf{X}^T \mathbf{Z} + \alpha \frac{1}{N_A} \sum_{t=1}^{N_A} \mathbf{Z}^T \mathbf{X}_t \mathbf{L}^{sw} \mathbf{X}_t^T \mathbf{Z} \right\} \end{aligned}$$

$$J_2 = \max \sum_{i,j=1}^N \|\mathbf{Z}^T \mathbf{x}_i - \mathbf{Z}^T \mathbf{x}_j\|^2 w_{ij}^b = \text{tr} (\mathbf{Z}^T \mathbf{X} \mathbf{L}^b \mathbf{X}^T \mathbf{Z}) \quad (4.10)$$

式中,  $\alpha (0 < \alpha < 1)$  表示正则化参数,  $\mathbf{L}^w = \mathbf{D}^w - \mathbf{W}^w$ ,  $\mathbf{L}^{sw} = \mathbf{D}^{sw} - \mathbf{W}^{sw}$ ,  $\mathbf{L}^b = \mathbf{D}^b - \mathbf{W}^b$ ,

$$\mathbf{D}^w = \text{diag} \left( \sum_{i,j=1}^N w_{ij}^w \right), \mathbf{D}^{sw} = \text{diag} \left( \sum_{i,j=1}^N w_{ij}^{sw} \right), \mathbf{D}^b = \text{diag} \left( \sum_{i,j=1}^N w_{ij}^b \right), \mathbf{W}^{sw} = \sum w_{ij}^{sw}, \mathbf{W}^b = \sum w_{ij}^b,$$

$$\mathbf{W}^w = \sum w_{ij}^w.$$

通过优化目标函数, 式(4.9)、(4.10)可转换为以下优化问题:

$$\min \frac{(1-\alpha) \mathbf{Z}^T \mathbf{X} \mathbf{L}^w \mathbf{X}^T \mathbf{Z} + \alpha \frac{1}{N_A} \sum_{t=1}^{N_A} \mathbf{Z}^T \mathbf{X}_t \mathbf{L}^{sw} \mathbf{X}_t^T \mathbf{Z}}{\mathbf{Z}^T \mathbf{X} \mathbf{L}^b \mathbf{X}^T \mathbf{Z}} \quad (4.11)$$

由拉格朗日乘子法可得:

$$(1-\alpha) \mathbf{Z}^T \mathbf{X} \mathbf{L}^w \mathbf{X}^T \mathbf{Z} + \alpha \frac{1}{N_A} \sum_{t=1}^{N_A} \mathbf{Z}^T \mathbf{X}_t \mathbf{L}^{sw} \mathbf{X}_t^T \mathbf{Z} = \lambda \mathbf{Z}^T \mathbf{X} \mathbf{L}^b \mathbf{X}^T \mathbf{Z} \quad (4.12)$$

通过求解式(4.12)的特征值, 按照降序选取前  $d$  个最大的特征值对应的特征向量组成投影矩阵  $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]$ 。

为进一步分析 SSRMDA 算法的运行效率, 在此用符号  $O$  表征计算复杂度。假设高光谱数据集的光谱波段数和像素个数分别为  $D$  和  $N$ , 那么  $(\mathbf{X} \mathbf{L}^b \mathbf{X}^T)^{-1}$  的计算复杂度为  $O(DN^2 + D^3)$ , 由于超像素内部的像素个数一般小于训练样本的个数, 则

$\mathbf{X}\mathbf{L}^w\mathbf{X}^T + 1/N_A \sum_{i=1}^{N_A} \mathbf{X}_i \mathbf{L}^{sw} \mathbf{X}_i^T$  的计算复杂度为  $O(DN^2)$ ，而特征值分解问题的计算复杂度为  $O(D^3)$ 。因此，SSRMDA 算法总的计算复杂度为  $O(DN^2 + N^3)$ ，本文算法的运行效率主要取决于遥感影像的光谱波段数  $D$  以及训练样本的个数  $N$ 。

表 4.1 SSRMDA 算法步骤

Table 4.1 Steps of SSRMDA algorithm

<p><b>Input:</b> 高光谱数据集 <math>\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \in \mathbf{R}^{D \times N}</math> 及其类别标签 <math>l_i \in \{1, 2, \dots, c\}</math>，类内近邻 <math>K_w = K_{sw} = K</math>，类间近邻 <math>K_b</math>，平衡参数 <math>\alpha</math>，超像素个数 <math>N_A</math>，嵌入维度 <math>d (d \ll D)</math>。</p> <p><b>Output:</b> 嵌入矩阵 <math>\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d] \in \mathbf{R}^{D \times d}</math>。</p>
<p><b>Step 1:</b> 对高光谱数据集进行预处理及归一化，对每类地物随机选取 <math>n_i</math> 个数据进行训练，其余用于测试；</p> <p><b>Step 2:</b> 构造光谱域类内图 <math>G^w = (\mathbf{X}, \mathbf{W}^w)</math> 和类间图 <math>G^b = (\mathbf{X}, \mathbf{W}^b)</math>，根据式(4.6)、(4.7)计算其权重分别得到 <math>w_{ij}^w</math>、<math>w_{ij}^b</math>；</p> <p><b>Step 3:</b> 利用 ERS 提取空间信息，构造正则化空间类内图 <math>G^{sw} = (\mathbf{X}, \mathbf{W}^{sw})</math>，并由式(4.8)计算其权重 <math>w_{ij}^{sw}</math>；</p> <p><b>Step 4:</b> 融合光谱信息和空间信息，由式(4.11)获得平衡参数 <math>\alpha</math>；</p> <p><b>Step 5:</b> 求解式(4.12)，选取前 <math>d</math> 个最大的特征值对应的特征向量组成低维嵌入矩阵 <math>\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_d]</math>。</p>

## 4.4 实验结果与分析

为验证 SSRMDA 的有效性，本章采用 Indian Pines 和 Washington DC Mall 高光谱数据集进行测试，并与其他相关算法作对比。

### 4.4.1 实验设置

实验时，每次实验皆从数据集中随机选取一定样本用于训练，其余样本作为测试。通过各特征提取算法得到低维嵌入特征后，采用最近邻分类器(1-NN)对地物进行分类，并以总体分类精度(OA)、平均分类精度(AA)及 *Kappa* 系数为分类结果的评价指标。

实验中，将本文提出的 SSRMDA 算法与 RAW、PCA、NPE、LPP、LDA、MFA、LGSFA、DSSM、LPNPE(Local Pixel NPE, LPNPE)<sup>[66]</sup>、SSRLDE (Spatial and Spectral Regularized Local Discriminant Embedding, SSRLDE)<sup>[66]</sup>进行对比。其中，RAW 表示未进行特征提取直接采用分类器进行分类的结果。为使各算法分类效果最优，采用交叉验证法获得其最佳参数，NPE、LPP 的近邻设置为 5，对于类内和类间近邻的设置，MFA 分别为 5、100，DSSM 分别为 3、5，SSRLDE 分别为 5、5，对于在 Indian Pines 和 Washington

DC Mall 数据集上空间窗口的设置, DSSM 为 11、11, LPNPE 为 15、5, SSRIDE 为 15、5。LDA 的嵌入维数为 ,  $c$  为类别数, 其余算法的嵌入维数均设置为 30。

为验证 SSRMDA 算法中不同光谱类内近邻  $K_w$ 、类间近邻  $K_b$ 、空间类内近邻  $K_{sw}$  以及空间正则化参数  $\alpha$  对分类性能的影响, 从数据集中每类随机选取 10 个样本进行训练, 其余样本作为测试论证。令超像素个数  $N_A = 100$ , 光谱类内近邻  $K_w$ 、空间类内近邻  $K_{sw}$  均用  $K$  表示,  $K$  和  $K_b$  的范围分别设置为  $\{3, 5, 7, \dots, 25\}$  和  $\{5, 10, 15, \dots, 50\}$ ,  $\alpha$  的范围设置为  $\{0, 0.1, 0.2, \dots, 1\}$ 。图 4.3 和图 4.4 分别为不同数据集上 SSRMDA 算法在不同  $K$ 、 $K_b$  及  $\alpha$  值下的平均总体分类精度。




图 4.3 SSRMDA 在不同  $K$ 、 $K_b$  值下的总体分类精度.

(a) Indian Pines; (b) Washington DC Mall

Fig. 4.3 OAs of SSRMDA with different  $K$  and  $K_b$  values.

(a) Indian Pines; (b) Washington DC Mall

分析图 4.3 可得知, 随着类内近邻  $K$  的增加, 总体分类精度先增加后减小, 造成此现象的原因是: 若  $K$  值较小, 则不能包含充足的同类空间和光谱信息, 而较大的  $K$  值一方面会增加邻域内含非同类数据的概率, 不利于鉴别特征的提取; 同时, 一定的  $K$  值下, 分类精度随  $K_b$  值的增加, 呈先上升达到稳定后下降的趋势, 由于  $K_b$  过大或过小都不能获得较好地类间区分度。实验中, 为使鉴别信息都充分得到应用, 进而促进算法表现最佳分类性能, 在 Indian Pines 数据集上,  $K = 11$ ,  $K_b = 20$ ; 在 Washington DC Mall 数据集上,  $K = 9$ ,  $K_b = 10$ 。

由图 4.4 可看出, 分类精度随着  $\alpha$  的增加呈现先增加后减小的变化规律。这是由于在 SSRMDA 算法中,  $\alpha$  用于平衡光谱信息和空间信息在特征提取中的作用,  $\alpha$  较小时, 容易忽略空间特征结构, 较大时, 未能充分利用光谱特征。实验中, 为使光谱信息和空间信息都得到有效利用, 对于 Indian Pines 数据集,  $\alpha = 0.8$ ; 对于 Washington DC Mall

数据集,  $\alpha = 0.3$ 。




图 4.4 SSRMDA 在不同  $\alpha$  值下的总体分类精度

Fig. 4.4 OAs of SSRMDA with different  $\alpha$  values

#### 4.4.2 Indian Pines 数据集实验

实验中, 为分析各算法在不同训练样本下的分类性能, 从每类地物中随机选取  $n_i$  个数据为训练样本, 其余为测试样本。表 4.2 为各算法在不同条件下 10 次随机实验的平均总体分类精度及其标准差,  $Kappa$  系数。

表 4.2 不同算法在 Indian Pines 数据集上的分类精度( $OA \pm std(\%)(Kappa)$ )

Table 4.2 The ( $OA \pm std(\%)(Kappa)$ ) of different methods on Indian Pines

算法	$n_i=5$	$n_i=10$	$n_i=15$	$n_i=20$
RAW	51.81 $\pm$ 2.37(0.463)	59.48 $\pm$ 1.72(0.547)	65.43 $\pm$ 1.39(0.613)	68.45 $\pm$ 1.03(0.645)
PCA	51.73 $\pm$ 2.39(0.462)	59.30 $\pm$ 1.71(0.545)	65.17 $\pm$ 1.36(0.610)	68.22 $\pm$ 0.98(0.643)
NPE	50.17 $\pm$ 2.32(0.445)	56.65 $\pm$ 1.81(0.516)	61.86 $\pm$ 1.67(0.574)	64.78 $\pm$ 1.35(0.605)
LPP	52.08 $\pm$ 2.09(0.467)	59.47 $\pm$ 1.80(0.547)	64.87 $\pm$ 1.68(0.607)	67.13 $\pm$ 1.35(0.631)
LDA	54.82 $\pm$ 2.38(0.498)	63.71 $\pm$ 1.70(0.595)	69.87 $\pm$ 1.55(0.662)	72.26 $\pm$ 1.06(0.688)
MFA	62.10 $\pm$ 3.79(0.577)	74.82 $\pm$ 2.03(0.716)	80.05 $\pm$ 1.35(0.775)	82.99 $\pm$ 1.20(0.807)
LGSFA	60.80 $\pm$ 4.10(0.563)	72.56 $\pm$ 1.94(0.691)	80.38 $\pm$ 1.62(0.778)	83.71 $\pm$ 0.99(0.815)
DSSM	54.15 $\pm$ 3.30(0.490)	62.63 $\pm$ 2.95(0.582)	72.08 $\pm$ 1.51(0.686)	74.44 $\pm$ 1.23(0.712)
LPNPE	56.81 $\pm$ 3.37(0.522)	70.14 $\pm$ 2.27(0.666)	76.89 $\pm$ 1.60(0.740)	81.97 $\pm$ 1.55(0.796)
SSRLDE	56.85 $\pm$ 3.19(0.523)	71.38 $\pm$ 2.80(0.680)	78.97 $\pm$ 2.64(0.763)	83.34 $\pm$ 1.97(0.812)
SSRMDA	<b>70.80<math>\pm</math>2.87(0.672)</b>	<b>82.14<math>\pm</math>2.65(0.798)</b>	<b>86.22<math>\pm</math>1.82(0.844)</b>	<b>89.21<math>\pm</math>1.51(0.876)</b>

由表 4.2 可知,随样本数增加,各算法的总体分类精度和 *Kappa* 系数都有明显提升,因为训练样本数的增多丰富了类别信息,使包含的有效特征越充足。与 RAW、PCA、NPE 等仅利用光谱信息的算法相比,DSSM、LPNPE 等融合了空间信息的算法分类性能大都较好,这是因为高光谱影像存在“同物异谱”和“同谱异物”现象(如 Corn-Notill 类别中一些样本的光谱曲线自身差异较大,即为“同物异谱”现象,但却与 Corn 类别中某些样本的光谱曲线更为接近,即为“同谱异物”现象),单纯的光谱分类未能很好地对地物类别进行区分,而空间信息的融入克服了这一缺点,增加了地物分类准确度。在不同训练样本下,本文提出的 SSRMDA 算法分类性能均表现最优,尤其是样本较少情况下,与其他对比算法分类效果差距较为突出,在训练样本为 5 时,其分类精度比 MFA 高 8.7%,这是由于 SSRMDA 不仅利用光谱信息构造了类内图和类间图来充分揭示高光谱影像潜在的低维流形结构,而且采用超像素方法提取了更为细致的空间信息,并将其作为正则项,有效平衡了光谱信息与空间信息在提取低维鉴别特征中的作用,进而提高了分类精度。

为分析各算法对影像每类地物的分类效果,从 Indian Pines 数据集中随机选取 2% 的数据作为训练学习,其余用于测试。表 4.3 为各算法对每类地物的分类效果,及定量描述的各指标参数值。图 4.5 为各算法学习后对应的分类结果图。

表 4.3 各算法对 Indian Pines 数据集上每类地物的分类精度(%)

类别	RAW	PCA	NPE	LPP	LDA	MFA	LGSA	DSSM	LPNPE	SSRLDE	SSRMDA
1	97.22	97.22	97.22	97.22	<b>100</b>	<b>100</b>	<b>100</b>	97.22	<b>100</b>	<b>100</b>	<b>100</b>
2	61.33	61.11	55.82	60.25	69.26	83.56	82.63	59.11	76.55	79.63	<b>86.92</b>
3	58.55	58.55	52.89	54.73	67.52	75.89	76.99	56.58	76.26	77.61	<b>89.54</b>
4	53.30	53.74	43.61	48.01	67.84	92.07	<b>93.83</b>	44.05	85.90	90.31	88.99
5	71.46	71.24	63.63	67.44	83.51	89.21	89.43	73.57	89.21	89.85	<b>91.12</b>
6	90.49	90.35	85.17	82.51	97.90	99.44	<b>99.58</b>	93.98	82.93	79.86	<b>99.58</b>
7	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>
8	87.82	87.82	77.35	81.19	71.58	97.43	97.65	88.03	92.52	<b>98.50</b>	97.43
9	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>
10	77.54	76.81	69.04	70.62	75.34	<b>89.08</b>	85.41	80.06	84.89	86.46	86.25
11	74.93	74.73	68.70	70.15	73.73	83.41	85.82	72.19	81.21	83.41	<b>92.02</b>
12	47.33	46.64	43.71	46.12	46.47	86.23	78.31	43.37	71.77	83.821	<b>90.88</b>
13	96.92	96.92	96.92	97.94	97.94	<b>98.97</b>	<b>98.97</b>	96.92	98.46	<b>98.97</b>	<b>98.97</b>
14	76.53	76.21	73.95	75.56	78.30	82.90	84.27	76.53	84.19	<b>85.80</b>	85.08
15	71.01	71.27	68.88	69.15	76.59	85.63	84.84	72.87	<b>91.49</b>	88.03	86.97
16	<b>100</b>	<b>100</b>	97.59	<b>100</b>	<b>100</b>	<b>100</b>	<b>100</b>	98.79	<b>100</b>	<b>100</b>	<b>100</b>
OA	72.24	72.01	66.61	68.54	74.66	86.37	86.31	71.33	82.46	84.66	<b>90.37</b>
AA	79.03	78.91	74.65	76.31	81.62	91.49	91.11	78.33	88.46	90.14	<b>93.36</b>



<i>Kappa</i>	0.684	0.682	0.620	0.642	0.712	0.845	0.844	0.674	0.800	0.826	<b>0.890</b>
--------------	-------	-------	-------	-------	-------	-------	-------	-------	-------	-------	--------------

从表 4.3 可看出, SSRMDA 算法在大多数地物中都得到了较好的分类精度, 且拥有最高的总体分类精度, 平均分类精度及 *Kappa* 系数, 由于 SSRMDA 算法能更好地挖掘高光谱影像中的鉴别信息。在基于光谱信息的特征提取方法中, 监督算法(LDA、MFA、LGSFA)取得了比非监督算法(PCA、NPE、LPP)更好的分类结果, 这是由于 LDA、MFA、LGSFA 利用了样本的先验标签信息, 能够获得更为有效的鉴别特征, 进而提升分类性能。同时, 空-谱算法(LPNPE, SSRLDE 和 SSRMDA)在大多数类别中取得了比光谱算法更好的分类结果, 这是因为高光谱影像具有空间一致性, 影像的块状效应比较明显, 相邻像素点一般具有比较明显的区域一致性, 这一特性可以用来帮助构建更为有效的维度约减模型。由于空-谱算法同时考虑了高光谱影像的空间结构和光谱信息, 因此能够取得更高的分类精度。然而, 在一定大小的区域内, 往往会掺杂有其他类别的样本点, 这些样本点会影响所构建空谱降维模型的准确性, 从而使得极个别类别的分类精度出现降低的情况。在图 4.5 中, 本文算法比其他算法产生的分类图更光滑, 噪点较少, 各类边界更明显, 相对完好的块区域更多, 与真实图更接近。




图 4.5 各算法在 Indian Pines 数据集上的分类图

Fig. 4.5 Classification maps of different methods on Indian Pines



### 4.4.3 Washington DC Mall 数据集实验

为验证 SSRMDA 算法在不同地物场景下的性能,同时选用 Washington DC Mall 数据集进行实验。实验时从数据集每类地物中随机选取  $n_i$  个数据作为训练集,剩余的为测试集。表 4.4 为在不同情况下各算法 10 次随机实验的平均总体分类精度及其标准差,  $Kappa$  系数。

表 4.4 不同算法在 Washington DC Mall 数据集上的分类精度( $OA \pm std(\%)(Kappa)$ )

Table 4.4 The ( $OA \pm std(\%)(Kappa)$ ) of different methods on Washington DC Mall				
算法	$n_i = 5$	$n_i = 10$	$n_i = 15$	$n_i = 20$
RAW	80.86 $\pm$ 2.96(0.761)	82.80 $\pm$ 2.23(0.786)	84.07 $\pm$ 2.17(0.802)	85.87 $\pm$ 1.86(0.824)
PCA	80.86 $\pm$ 2.96(0.761)	82.79 $\pm$ 2.23(0.786)	84.06 $\pm$ 2.18(0.802)	85.86 $\pm$ 1.86(0.824)
NPE	79.91 $\pm$ 3.33(0.750)	81.20 $\pm$ 3.06(0.767)	82.91 $\pm$ 2.13(0.788)	84.94 $\pm$ 1.74(0.812)
LPP	80.21 $\pm$ 3.35(0.753)	82.24 $\pm$ 1.91(0.779)	83.47 $\pm$ 1.87(0.795)	85.46 $\pm$ 1.81(0.819)
LDA	81.56 $\pm$ 3.33(0.770)	83.08 $\pm$ 2.23(0.790)	85.52 $\pm$ 1.77(0.820)	86.69 $\pm$ 1.48(0.834)
MFA	84.49 $\pm$ 2.51(0.806)	87.92 $\pm$ 2.25(0.849)	90.98 $\pm$ 2.20(0.887)	91.87 $\pm$ 0.89(0.898)
LGSFA	85.48 $\pm$ 2.68(0.818)	88.53 $\pm$ 2.20(0.857)	91.28 $\pm$ 1.15(0.891)	92.47 $\pm$ 1.03(0.906)
DSSM	80.63 $\pm$ 3.31(0.759)	82.80 $\pm$ 2.19(0.786)	84.08 $\pm$ 2.57(0.802)	85.33 $\pm$ 2.11(0.817)
LPNPE	78.71 $\pm$ 5.15(0.736)	86.65 $\pm$ 2.63(0.834)	87.75 $\pm$ 2.36(0.847)	89.14 $\pm$ 1.02(0.864)
SSRLDE	79.45 $\pm$ 5.36(0.744)	86.51 $\pm$ 4.22(0.832)	87.34 $\pm$ 3.30(0.843)	89.62 $\pm$ 1.37(0.870)
SSRMDA	<b>88.73<math>\pm</math>2.15(0.859)</b>	<b>92.78<math>\pm</math>1.19(0.910)</b>	<b>94.04<math>\pm</math>0.98(0.925)</b>	<b>95.35<math>\pm</math>0.73(0.942)</b>

分析表 4.4 可知,各算法的总体分类精度和  $Kappa$  系数随样本数增多均呈上升趋势,由于高光谱影像的鉴别信息随样本数增多可利用的越充足。DSSM、LPNPE 等加入了空域特征的算法,在大多数训练条件下都优于如 RAW、PCA、NPE 等光谱域算法。相较于 DSSM、LPNPE 和 SSRLDE 等空-谱算法,SSRMDA 算法在各种训练条件均有明显的提高,因其通过构造空域类内图以作正则化处理,在充分表达空间特征的同时,增强了类内聚集性。在不同实验条件下,SSRMDA 均较其他算法分类精度高,这是由于 SSRMDA 在充分表达光谱域特征的同时加入了空间信息,空-谱结合更有利于强化类内信息聚集和类间信息分散,增加数据可分性,从而改善地物分类性能。

为对比不同算法对每类地物的分类效果,从 Washington DC Mall 数据集中随机选取 1%的数据作为训练学习得到低维嵌入矩阵,剩余的作为测试样本进行验证。表 4.5 给出了各算法对每类地物的分类情况。图 4.6 为各算法相应的分类效果图。

表 4.5 各算法在 Washington DC Mall 数据集上每类地物的分类精度(%)

Table 4.5 Classification accuracy of each class on Washington DC Mall by different methods(%)											
类别	RAW	PCA	NPE	LPP	LDA	MFA	LGSFA	DSSM	LPNPE	SSRLDE	SSRMDA
1	95.04	95.01	94.71	94.38	94.76	97.83	98.71	95.17	93.72	95.06	<b>99.79</b>

2	94.12	94.12	93.57	94.74	96.33	97.24	98.22	94.13	<b>99.26</b>	96.45	98.39
3	87.67	87.64	86.56	86.53	88.33	91.40	93.15	87.64	96.93	95.39	<b>98.61</b>
4	97.34	97.34	97.01	97.27	97.37	97.88	97.88	97.34	97.08	96.40	<b>98.73</b>
5	66.83	66.89	64.04	69.39	72.35	89.52	93.20	66.66	91.86	82.38	<b>93.76</b>
6	67.90	67.90	65.03	67.73	68.20	73.78	80.46	67.86	72.85	72.05	<b>82.66</b>
OA	88.09	88.08	87.05	87.91	88.87	92.81	94.64	88.11	92.90	91.64	<b>96.70</b>
AA	84.82	84.82	83.49	85.01	86.22	91.28	93.60	84.80	91.95	89.62	<b>95.49</b>
Kappa	0.850	0.849	0.837	0.848	0.860	0.909	0.933	0.850	0.911	0.895	<b>0.959</b>

由表 4.5 可知, 本文算法在 Washington DC Mall 数据集上的所有地物分类效果皆较好, 且各评价指标参数均最高, 说明 SSRMDA 能充分揭示该数据中潜在的低维流形, 很好地表达其内在特性。对于只采用光谱信息的特征提取算法, 由于监督算法利用了样本的先验标签信息, 因此各类别取得了更高的分类精度。而空-谱算法由于融合了高光谱影像的空间结构信息, 能够得到更为有效的鉴别特征, 因此在大多数类别中取得了比光谱算法更好的分类结果。此外, 在图 4.6 中, SSRMDA 算法分类图较其他算法更为平滑, 地物分类更清晰, 更接近于实际地物图。由此可见, 本文提出的空间正则化流形鉴别分析算法能更好地提取地物内在特征, 提高分类性能。




图 4.6 各算法在 Washington DC Mall 数据集上的分类图

Fig. 4.6 Classification maps of different methods on Washington DC Mall

#### 4.4.4 实验结论

通过 SSRMDA 在 Indian Pines 和 Washington DC Mall 两个高光谱数据集上的实验,

可得到以下结论:

① 在不同训练样本下,本章提出的 SSRMDA 算法分类效果均是最优。且大多数情况下,监督类算法(LDA、MFA、LGSFA、DSSM、LPNPE、SSRLDE、SSRMDA)比非监督算法(PCA、NPE、LPP)分类结果更好,因为监督类算法利用了数据的类别标签信息,加入先验信息,增强了有效信息的表达,使得提取的特征更有鉴别力,从而增强分类性能。

② SSRMDA、DSSM 等空-谱算法比 PCA、NPE 等光谱算法分类精度普遍更高。因为空间信息的融入增加了高光谱数据的特征表达,充分揭示了高光谱影像的内在结构。同是空-谱算法,SSRMDA 却比 DSSM、LPNPE 和 SSRLDE 具有更好的分类效果,主要区别在于空间特征的提取方式不同。DSSM、LPNPE 和 SSRLDE 采用加窗方式来提取特征,其空间邻域特征大小固定,易造成信息缺失。而 SSRMDA 利用超像素提取的空间信息更细致,超像素大小和形状可根据数据的局部结构自适应调整,避免丢失信息。

③ 在 Indian Pines 和 Washington DC Mall 数据集上,SSRMDA 总体分类精度分别达到 91.58% 和 96.67%,较其他算法都有明显提高,特别是小样本条件下优势更为明显,有利于实际应用场景。从分类结果图看,本章算法分类图更加平滑,错分现象较轻。因为 SSRMDA 通过光谱图和空间图的构造,较好的融合了光谱特征和空间特征,并使得类内数据聚集且类间数据分散,以提取鉴别特征。

## 4.5 本章小结

本章针对高光谱影像蕴含丰富的光谱信息和空间信息,且传统特征提取算法大都只研究光谱信息或者未能充分获取空间信息的问题,提出了一种监督空间正则化流形鉴别分析算法(SSRMDA),以提高地物分类精度。该算法基于空-谱联合思想,首先利用光谱信息构造类内图和类间图以描述复杂的谱域特征,以揭示高光谱数据中内在的低维流形结构,同时利用空间信息构建类内图并且以正则化方式融入特征提取目标函数中,可有效解决过拟合学习问题,并在低维空间中加强了类内数据聚集度,有效提高了嵌入特征的鉴别能力。在 Indian Pines 和 Washington DC Mall 数据集上实验结果说明,SSRMDA 更好地表征了高光谱数据的内在结构,获取的特征更有鉴别力,可以更高效地改善地物分类精度。

## 5 总结与展望

### 5.1 工作总结

高光谱遥感突破了传统的全色遥感和多光谱遥感在光谱分辨率及波段数方面的局限性。高光谱遥感影像光谱区域延伸较广，且拥有较高的光谱分辨率。覆盖可见光到近红外光谱区域的数十上百个波段，波段间窄而连续，每个像素都包含一条光谱曲线，能够提供丰富的地物信息，实现地物的精细识别与分类。现已被广泛应用于农作物监测、灾害监测、气象监测、资源勘探、大气环境、军事侦察等领域。然而，高光谱影像存在波段众多、波段间相关性强、数据量大，冗余度高，易造成“维数灾难”等问题，使高光谱遥感影像在地物分类过程中受到限制。因此，如何提取具有解释性的鉴别特征成为解决上述问题的关键。

本文根据高光谱遥感影像数据结构，重点研究如何从高光谱数据中提取出有效的鉴别特征，进而改善地物分类性能。在基于流形学习的图嵌入模型下，提出了两种特征提取算法，并在不同的高光谱遥感影像数据集上进行了论证分析。本文主要工作总结如下：

① 总结了遥感技术的发展历程，介绍了高光谱影像的数据特点及其带来的挑战，并得出特征提取的必要性。详细地介绍了高光谱遥感成像技术和特征提取的国内外研究现状。

② 介绍了全局线性特征提取算法，由于其不能揭示高光谱遥感影像数据的内在非线性几何结构，从而引出流形学习。简单表述了流形的相关理论知识，并从非线性流形学习、线性流形学习、多流形学习及空-谱流形学习几个角度介绍了几种常用的流形学习特征提取算法，概括了各算法的思想原理、实现过程及优势与不足。简要介绍了高光谱影像地物分类结果的评价指标：总体分类精度、平均分类精度及 *Kappa* 系数，以及本文实验过程中用到的高光谱影像数据集。

③ 针对传统单流形特征提取算法不能有效揭示高光谱数据中的潜在多流形结构的不足，研究提出了一种监督多流形鉴别嵌入 (SMMDE) 特征提取算法。该算法利用样本类别信息进行子流形的划分，利用图嵌入模型构造了流形内图和流形间图，并定义了流形内距离和流形间距离，在低维嵌入过程中通过最大化流形间距离和最小化流形内距离以更好地获得每个子流形的鉴别特征，从而实现特征提取。根据 PaviaU 和 KSC 高光谱数据集上的实验结果分析可知，在相同实验条件下，本文提出的 SMMDE 算法更能表达高光谱数据的多流形结构，提取出解释力更强的鉴别特征，实现较好的地物分类效果。

④ 基于流形学习中的图嵌入原理和影像空间信息，研究提出了一种融合空间-光谱信息的监督空间正则化流形鉴别分析 (SSRMDA) 特征提取算法。该算法利用样本标签信

息,在光谱域构造类内图和类间图以描述光谱特征,采用熵率超像素方法充分提取高光谱影像的空间信息,并构造空域类内图,以表征影像的空间几何结构。将空间信息与光谱信息按正则化方式结合,较好地平衡了空间特征和光谱特征在低维空间中的作用,并强化了类内数据的聚集性,有效提取了空-谱鉴别特征,进而提高了高光谱影像地物分类精度。在 Indian Pines 和 Washington DC Mall 高光谱数据集上的测试结果表明,SSRMDA 提取的特征更有鉴别力,获得更好的分类结果,分类性能相对其他算法更好。

## 5.2 研究展望

面对高光谱遥感影像地物分类阶段存在的“维数灾难”,本文研究提出了两种新的基于流形学习的特征提取算法,去除了不必要的特征,降低了数据冗余,并且揭示了数据在低维可视空间的几何分布特点,对地物分类性能有了一定的提高。但在算法的发展方面,仍存在许多可以改善的地方。在后续研究中,主要从以下几方面开展工作:

① 对比第 3 章和第 4 章的内容,高光谱遥感影像数据存在多流形结构,即不同类别的子集对应不同的子流形结构,且在高光谱影像中地物蕴含丰富的空间信息。而第 3 章所提算法仅揭示了高光谱数据的几何分布特点为多流形结构,并未考虑影像中蕴藏的地物空间特征,同时,第 4 章中提出的算法又只考虑了在光谱信息中融入地物的空间信息,并未表征高光谱影像数据的内在多流形几何结构。因此,在今后的研究工作中,可综合考虑数据的空间信息和多流形结构,从空-谱多流形角度出发,进一步增进高光谱影像地物分类效果。

② 高光谱影像分析处理过程中,特征提取算法和分类算法对地物分类结果都有很大程度的影响,而本文提出的两种算法均从鉴别特征提取的角度来改善地物分类效果,并未对分类器进行研究。因此,在下一步工作中,将对现有高光谱影像分类算法进行研究,并在此基础上,研究合适的分类器模型,进一步改善地物分类效果。

## 参 考 文 献

- [1] 孙家柄. 遥感原理与应用(第3版) [M]. 武汉: 武汉大学出版社, 2013.
- [2] 蔡国印, 杜明义. 遥感技术基础双语讲义 [M]. 武汉: 武汉大学出版社, 2016.
- [3] 方臣, 胡飞, 陈曦, 朱正勇, 刘烨青, 叶琴. 自然资源遥感应用研究进展[J]. 资源环境与工程, 2019, 33(04): 563-569.
- [4] 和海霞, 杨思全, 陈伟涛, 等. 环境减灾卫星高光谱数据在减灾中的应用研究 [J]. 航天器工程, 2011, 20(6): 118-125.
- [5] 石菲菲, 朱谷昌. 高光谱遥感在东天山玉带地区地质调查中的应用[J]. 矿产勘查, 2019, 10(11): 2753-2757.
- [6] 叶满珠, 廖世芳. 高光谱技术在农业遥感中的应用[J]. 农业工程, 2018, 8(10): 38-40.
- [7] E. A. Cloutis. Review Article Hyperspectral geological remote sensing: evaluation of analytical techniques [J]. International Journal of Remote Sensing, 1996, 17(12): 2215-2242.
- [8] A. Börnera, L. Wiest, P. Kellerb, et al. SENSOR: a tool for the simulation of hyperspectral remote sensing systems [J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2001, 55(5-6): 299-312.
- [9] V. E. Brando, A. G. Dekker. Satellite hyperspectral remote sensing for estimating estuarine and coastal water quality [J]. IEEE Transactions on Geoscience and Remote Sensing, 2003, 41(6): 1378-1387.
- [10] L. Eriksson, A. Kullgren. Influence of seat geometry and seating posture on NIC max long-term AIS 1 neck injury predictability [J]. Traffic Injury Prevention, 2006, 7(1): 61-69.
- [11] R. O. Green, M. L. Eastwood, C. M. Sarture, et al. Imaging spectroscopy and the airborne visible/infrared imaging spectrometer (AVIRIS) [J]. Remote Sensing of Environment, 1998, 65(3): 227-248.
- [12] R. G. Resmini, M. E. Kappus, W. S. Aldrich, et al. Mineral mapping with hyperspectral digital imagery collection experiment (HYDICE) sensor data at Cuprite, Nevada, USA [J]. International Journal of Remote Sensing, 1997, 18(7): 1553-1570.
- [13] A. Barducci, P. Marcoionni, I. Pippi. Recent advances in Earth remote sensing: Fourier Transform Stationary HyperSpectral Imagers [J]. Annals of Geophysics, 2006, 49(1): 103-107.
- [14] L. S. Galvão, A. R. Formaggio, D. A. Tisot. Discrimination of sugarcane varieties in Southeastern Brazil with EO-1 Hyperion data [J]. Remote Sensing of Environment, 2005, 94(4): 523-534.
- [15] R. B. Lockwood, T. W. Cooley, et al. Advanced responsive tactically-effective military imaging spectrometer (ARTEMIS) design[C]. IEEE International Conference on Geoscience and Remote Sensing Symposium. USA: IEEE, 2006: 1628-1630.
- [16] R. L. Lucke, M. Corson, N. R. McGlothlin, et al. The hyperspectral imager for the coastal ocean

- (HICO):fast build for the ISS[J]. Remote Sensing System Engineering III, 2010, 7813.
- [17] P. A. Fletcher. Image Acquisition planning for the CHRIS sensor on board PROBA [J]. Proceedings of SPIE–The International Society for Optical Engineering, 2004, 5546: 141-148.
- [18] M. Rast, J. L. Bezy. The ESA medium resolution imaging spectrometer MERIS: A Review of the Instrument and Its Mission [J]. International Journal of Remote Sensing, 1999, 20(9): 1681-1702.
- [19] 李天宏, 杨海宏, 赵永平. 成像光谱仪遥感现状与展望 [J]. 遥感技术与应用, 1997, 12(2): 55-59.
- [20] 方抗美. 模块化机载成像光谱仪光学系统 [C]. 第六届成像光谱技术与应用研讨会, 云南丽江, 2006, 125-129.
- [21] 崔毅, 危峻, 汤瑜瑜, 等. 适用于推扫式成像光谱仪的 CCD 拖尾扣除方法 [J]. 光谱学与光谱分析, 2014, 34(7): 1990-1994.
- [22] 刘银年, 薛永祺, 王建宇, 等. 实用型模块化成像光谱仪 [J]. 红外与毫米波学报, 2002, 21(1): 9-14.
- [23] 胡秀清, 刘京晶, 邱康睦, 等. 神舟 3 号飞船中分辨率成像光谱仪场地替代定标新方法研究 [J]. 光谱学与光谱分析, 2009, 29(5): 1153-1159.
- [24] 赵葆常, 杨建峰, 薛彬, 等. 嫦娥一号干涉成像光谱仪的定标 [J]. 光子学报, 2010, 39(5): 769-775.
- [25] 漆成莉, 顾明剑, 胡秀清, 等. 风云三号卫星红外高光谱探测技术及潜在应用 [J]. 气象科技进展, 2016, 6(1): 88-93.
- [26] 高铭, 张善从, 李盛阳. “天宫一号” 高光谱成像仪遥感应用[J]. 遥感学报, 2014, 18(S1): 2-10.
- [27] 曹福成. 高分系列遥感卫星布设中国太空“慧眼”——我国高分专项建设回眸 [J]. 中国军转民, 2015, (1): 28-33.
- [28] 范斌, 陈旭, 李碧岑, 等 “高分五号” 卫星光学遥感载荷的技术创新[J]. 红外与激光工程, 2017, 46(1): 8-14.
- [29] 李先怡, 范海生, 潘申林, 等. 珠海一号高光谱卫星数据及应用概况[J]. 卫星应用, 2019, 000(008):12-18.
- [30] 叶珍. 高光谱图像特征提取与分类算法研究 [D]. 西安: 西北工业大学, 2015.
- [31] S. Prasad, L. M. Bruce. Limitations of principal components analysis for hyperspectral target recognition [J]. IEEE Geoscience and Remote Sensing Letters, 2008, 5(4): 625-629.
- [32] T. V. Bandos, et al. Classification of hyperspectral images with regularized linear discriminant analysis [J]. IEEE Transactions on Geoscience and Remote Sensing, 2009, 47(3): 862-873.
- [33] U. Amato, R. M. Cavalli, A. Palombo, et al. Experimental approach to the selection of the components in the minimum noise fraction [J]. IEEE Transactions on Geoscience and Remote Sensing, 2009, 47(1): 153-160.
- [34] J. Kruskal. Multidimensional scaling by optimizing goodness of fit to a nonmetric hypothesis [J]. Psychometrika, 1964, 29(1): 1-27.

- [35] C. M. Bachmann, T. L. Ainsworth, R. A. Fusina. Exploiting manifold geometry in hyperspectral imagery [J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2005, 43(3): 441-454.
- [36] J. B. Tenenbaum, V. d. Silva, J. C. Langford. A global geometric framework for nonlinear dimensionality reduction [J]. *Science*, 2000, 290(5500): 2319-2323.
- [37] S. T. Roweis, L. K. Saul. Nonlinear dimensionality reduction by locally linear embedding [J]. *Science*, 2000, 290(5500): 2323-2326.
- [38] M. Belkin, P. Niyogi. Laplacian eigenmaps for dimensionality reduction and data representation [J]. *Neural Computation*, 2003, 15(6): 1373-1396.
- [39] Z. Zhang, H. Zha. Principal manifolds and nonlinear dimensionality reduction via tangent space alignment [J]. *Journal of Shanghai University (English Edition)*, 2004, 8(4): 406-424.
- [40] X. F. He, D. Cai, S. C. Yan, et al. Neighborhood preserving embedding [C]. *Proceedings of the Tenth IEEE International Conference on Computer Vision (ICCV)*, Beijing, China, 2005, 2: 1208-1213.
- [41] X. F. He, P. Niyogi. Locality preserving projections [C]. *Neural Information Processing Systems*, 2004, 16: 153-160.
- [42] T. H. Zhang, J. Yang, D. L. Zhao, et al. Linear local tangent space alignment and application to face recognition [J]. *Neurocomputing*, 2007, 70(7-9): 1547-1553.
- [43] S. C. Yan, D. Xu, B. Y. Zhang, et al. Graph embedding and extensions: a general framework for dimensionality reduction [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2007, 29(1): 40-51.
- [44] F. L. Luo, H. Huang, Y. L. Duan, et al. Local geometric structure feature for dimensionality reduction of hyperspectral imagery [J]. *Remote Sensing*, 2017, 9(8): 6197-6211.
- [45] M. Lv, Q. L. Hou, et al. Collaborative discriminative manifold embedding for hyperspectral imagery [J]. *IEEE Geoscience and Remote Sensing Letters*, 2017, 14(4): 569-573.
- [46] R. Hettiarachchi, J. F. Peters. Multi-manifold LLE learning in pattern recognition [J]. *Pattern Recognition*, 2015, 48(9): 2947-2960.
- [47] K. Shil, J. S. Hao, X. Zhang. Image recognition method based on supervised multi-manifold learning [J]. *Journal of Intelligent & Fuzzy Systems*, 2017, 32(3): 2221-2232.
- [48] W. Yang, C. Sun, L. Zhang. A multi-manifold discriminant analysis method for image feature extraction [J]. *Pattern Recognition*, 2011, 44(8): 1649-1657.
- [49] J. Lu, Y. P. Tan, G. Wang. Discriminative Multimanifold Analysis for Face Recognition from a Single Training Sample per Person [J]. *Pattern Analysis & Machine Intelligence IEEE Transactions on*, 2013, 35(1): 39-51.
- [50] 王立志, 黄鸿, 冯海亮. 多线性局部与全局保持嵌入在高光谱遥感影像分类中的应用[J]. *计算机辅助设计与图形学学报*, 2012, 24(6): 780-786.



- [51] M. Fauvel, Y. Tarabalka, J. A. Benediktsson, et al. Advances in spectral-spatial classification of hyperspectral images [J]. *Proceedings of the IEEE*, 2013, 101(3):652-675.
- [52] 魏峰, 何明一, 梅少辉. 空间一致性邻域保留嵌入的高光谱数据特征提取[J]. *红外与激光工程*, 2012, 41(5): 1249-1254.
- [53] Z. X. Feng, S. Y. Yang, et al. Discriminative spectral-spatial margin-based semi-supervised dimensionality reduction of hyperspectral data [J]. *IEEE Geoscience and Remote Sensing Letters*, 2014, 12(2): 224-228.
- [54] 侯榜焕, 姚敏立, 等. 面向高光谱图像分类的空-谱判别分析[J]. *光学精密工程*, 2018, 26(2): 450-460.
- [55] 李春光. 流形学习及其在模式识别中的应用 [D]. 北京: 北京邮电大学, 2007.
- [56] 李波. 基于流形学习的特征提取方法及其应用研究 [D]. 合肥: 中国科学技术大学, 2008.
- [57] R. G. Congalton. A review of assessing the accuracy of classifications of remotely sensed data [J]. *Remote Sensing of the Environment*, 1991, 37(1): 35-46.
- [58] Hyperspectral data set [OL]. [http://www.ehu.eus/ccwintco/index.php?title=Hyperspectral\\_Remote\\_Sensing\\_Scenes](http://www.ehu.eus/ccwintco/index.php?title=Hyperspectral_Remote_Sensing_Scenes).
- [59] Hyperspectral data set [OL]. <https://engineering.purdue.edu/~biehl/MultiSpec/hyperspectral.html>.
- [60] R. Xiao, Q. J. Zhao, et al. Facial expression recognition on multiple manifolds [J]. *Pattern Recognition*, 2011, 44(1): 107-116.
- [61] T. Denœux. A k-Nearest Neighbor Classification Rule Based on Dempster-Shafer Theory [J]. *IEEE Transactions on Systems Man and Cybernetics*, 1995, 25(5): 804-813.
- [62] X. Ren, J. Malik. Learning a classification model for segmentation [J]. *Proceedings of the Ninth IEEE International Conference on Computer Vision*, 2003, 1:10-17.
- [63] M. Y. Liu, O. Tuzel, S. Ramalingam, et al. Entropy rate superpixel segmentation [J]. *Computer Vision and Pattern Recognition*, 2011, 32(14): 2097-2104.
- [64] J. Guo, X. Zhou, J. Li, et al. Superpixel-based active learning and online feature importance learning for hyperspectral image analysis [J]. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2017, 10(1): 347-359.
- [65] J. J. Jiang, J. Y. Ma, C. Chen, et al. SuperPCA: a superpixelwise PCA approach for unsupervised feature extraction of hyperspectral imagery [J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2018, 56(8): 4581-4593.
- [66] Y. C. Zhou, J. T. Peng, C. L. P. Chen. Dimension reduction using spatial and spectral regularized local discriminant embedding for hyperspectral image classification [J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2015, 53(2): 1082-1095.

## 附 录

### A. 作者攻读硕士学位期间发表的论文

- [1] 黄鸿, 王丽华, 石光耀. 面向高光谱影像分类的空间正则化流形鉴别分析方法[J]. 光学学报, 2020, 40(2): 0228001.
- [2] 黄鸿, 王丽华, 石光耀. 面向高光谱遥感影像分类的监督多流形鉴别嵌入方法[J]. 电子学报, 2019. (稿号: C190132, 已录用).
- [3] 黄鸿, 陈美利, 王丽华, 李政英. 空-谱协同正则化稀疏超图嵌入的高光谱图像分类[J]. 测绘学报, 2019, 48(06): 676-687.
- [4] Guangyao Shi, Hong Huang, Lihua Wang. Unsupervised Dimensionality Reduction for Hyperspectral Imagery via Local Geometric Structure Feature Learning [J]. IEEE Geoscience and Remote Sensing Letters, 2019, 99: 1-5.

### B. 作者在攻读硕士学位期间参与的科研项目及获奖情况

- [1] 国家自然科学基金(41371338), 重庆市研究生科研创新项目(CYB19039).
- [2] 2019-2020 年在研究生争先创优活动中, 表现突出获得 “重庆大学优秀毕业研究生” .
- [3] 2018-2019 年在研究生争先创优活动中, 表现突出获得 “重庆大学优秀研究生” .

## C. 学位论文数据集

关键词		密级		中图分类号	
高光谱影像；特征提取； 流形学习；空-谱联合信息； 图嵌入		公开		TP751	
学位授予单位名称	学位授予单位代码	学位类别		学位级别	
重庆大学	10611	学术学位		硕士	
论文题名		并列题名		论文语种	
基于空-谱流形学习的高光谱 影像特征提取研究		无		中文	
作者姓名	王丽华	学号		20170802019t	
培养单位名称		培养单位代码			
重庆大学		10611			
学科专业	研究方向	学制		学位授予年	
仪器科学与技术	图像处理	3		2020.06	
论文提交日期	2020.06	论文总页数		68	
导师姓名	黄鸿	职称		教授	
答辩委员会主席		刘玉菲			
电子版论文提交格式					
文本（√）    图像（）    视频（）    音频（）    多媒体（）    其他（）					

## 致 谢

白驹过隙,时光匆匆流淌,研究生三年的求学生涯即将告一段落。回顾三年的点滴,心中充满留恋与感动。趁此论文完成之际,我真诚地向那些引导我、帮助我、鼓励我的老师、同学、家人表示衷心的感谢!

诚挚感谢我的导师黄鸿教授,论文的研究工作是在黄老师的精心指导和悉心关怀下完成的。感激黄老师的培养,带我走进 1316 实验室大家庭,当我在学术上迷茫的时候,黄老师给予我耐心引导,给我确定了研究方向。黄老师学术知识广博、治学态度严谨、思维睿智,总能在学术研究中给我提出建设性的宝贵意见,并为我们创造积极的学术氛围、轻松的科研环境。黄老师扎实的科研知识、勤勉的工作态度、谦虚的为人处世风格激励着我在今后的学习、工作和生活中更加努力进取。师恩伟大,感谢黄老师一直以来的谆谆教导,在此真挚地祝福您身体健康、桃李满天下。

感谢 1316 实验室所有师兄、师姐、师弟、师妹在研究生期间给予我的支持和帮助。特别感谢石光耀师兄在课题研究中对我的细心帮助,每次遇到问题,总是第一个请教师兄,感激师兄的耐心指导;感谢同届的唐玉梏、杨松同学,三年来给予了我许多帮助;感谢师母谭崎娟女士,时常带领大家策划活动,整理实验室卫生,给我们营造了温馨、整洁的科研氛围。

感谢我的父母亲人对我的信任、鼓励与支持,你们对我无私的爱和奉献给予了我源源不断的动力,让我能健康成长,全心学习,拥有你们是我人生中最美好的幸福。

感谢 4 舍 306 宿舍的小伙伴们,在平时的生活中对我的关心和照顾,感恩遇到你们,祝愿你们生活愉快,前程似锦。

诚挚感谢在百忙之中参与论文评阅和答辩的各位专家、教授!

**王丽华**

二〇二〇年五月 于重庆